

Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH



Instytut Informatyki

Praca dyplomowa inżynierska

na kierunku Informatyka
w specjalności Sztuczna Inteligencja

Poprawa efektywności CMA-ES jako algorytmu optymalizacji globalnej

Maksym Bieńkowski

Numer albumu 325147

promotor
prof. dr hab. inż. Jarosław Arabas

WARSZAWA 2026

Poprawa efektywności CMA-ES jako algorytmu optymalizacji globalnej

Streszczenie

Przedmiotem pracy jest wykorzystanie charakterystycznych właściwości algorytmu optymalizacji ciągłej *Covariance Matrix Adaptation Evolution Strategy* (CMA-ES) oraz metod zmiennej metryki poprzez propozycję optymalizatora hybrydowego łączącego CMA-ES oraz algorytm *Broyden-Fletcher-Goldfarb-Shanno* (BFGS). Kluczową ideą proponowanego algorytmu CMABFGS jest wykorzystanie macierzy kowariancji CMA-ES jako wstępnego przybliżenia odwrotności hesjanu funkcji celu podczas inicjacji BFGS.

Przeprowadzona analiza tempa zbieżności inicjowanego w ten sposób BFGS dla funkcji kwadratowych wskazuje na możliwość istotnego przyspieszenia zbieżności względem wariantu bazowego, w którym początkową wartością przybliżenia odwrotności hesjanu jest macierz jednostkowa.

Porównanie na zestawie funkcji benchmarkowych CEC2017 wskazuje, że w ujęciu zagregowanym proponowany sposób hybrydyzacji może prowadzić do poprawy efektywności względem zarówno CMA-ES, jak i BFGS.

Słowa kluczowe: optymalizacja, optymalizacja hybrydowa, CMA-ES, BFGS, algorytmy metaheurystyczne

Improving the efficiency of CMA-ES as a global optimization algorithm

Abstract

The focus of this thesis lies in the use of intrinsic properties of the Covariance Matrix Adaptation Evolution Strategy (CMA-ES) continuous optimization algorithm and variable metric methods through proposing a hybrid optimizer combining CMA-ES and the Broyden-Fletcher-Goldfarb-Shanno (BFGS) algorithm. The key idea behind the proposed CMABFGS algorithm is to use the CMA-ES covariance matrix as a preliminary approximation of the inverse Hessian of the objective function during BFGS initialisation.

The analysis of convergence rate on quadratic functions shows a significant acceleration of BFGS preconditioned in this way compared to the base variant, in which the initial approximation of the inverse Hessian is the identity matrix.

A comparison on the CEC2017 benchmark function set indicates that, in aggregate terms, the proposed hybridisation method can lead to improved efficiency compared to both CMA-ES and BFGS.

Keywords: optimization, hybrid optimization, CMA-ES, BFGS, metaheuristic algorithms

Spis treści

1 Wprowadzenie	1
1.1 Tło i motywacja	1
1.2 Cel i hipotezy badawcze	1
2 Przegląd literatury	3
2.1 Algorytm CMA-ES	3
2.2 Algorytm BFGS	7
2.3 Porównywanie metod optymalizacji	8
2.3.1 Krzywe zbieżności	8
2.3.2 Krzywe ECDF	8
2.3.3 Zestawy funkcji benchmarkowych i konkurs CEC	9
2.3.4 Problemy w porównywaniu metod optymalizacji	9
2.4 Środowiska implementacji	10
3 Przeprowadzone badania	11
3.0.1 Przyjęte ustawienia algorytmów	11
3.0.2 Kryteria zatrzymania algorytmów	11
3.1 Badanie zbieżności macierzy kowariancji algorytmu CMA-ES do odwrotności hesjanu funkcji celu	11
3.1.1 Cel badania	11
3.1.2 Metodyka	12
3.1.3 Analiza zbieżności macierzy kowariancji do odwrotności hesjanu funkcji celu w oparciu o krzywe zbieżności	13
3.1.4 Porównanie z wynikami znanymi z literatury	17
3.1.5 Wnioski	17
3.2 Przyspieszenie zbieżności BFGS przy pomocy macierzy kowariancji z CMA-ES dla unimodalnej funkcji kwadratowej	17
3.2.1 Cel badania	17
3.2.2 Metodyka	18
3.2.3 Omówienie wyników badania	19
3.2.4 Wnioski	22
3.3 Algorytm CMABFGS	23
3.3.1 Motywacja i zarys algorytmu	23
3.3.2 Uwagi implementacyjne	24
3.4 Porównanie zbieżności CMA-ES, BFGS i CMABFGS z uwzględnieniem ograniczeń	24
3.4.1 Cel badania	24
3.4.2 Metodyka	25
3.4.3 Omówienie wyników badania	27
3.4.4 Wnioski	30
3.5 Porównanie zbieżności algorytmów CMA-ES, BFGS oraz CMABFGS na zbiorze funkcji CEC2017	31
3.5.1 Cel badania	31

3.5.2	Metodyka	31
3.5.3	Omówienie wyników badania	32
3.5.4	Wniosek	37
4	Podsumowanie	38
4.1	Podsumowanie badań	38
4.2	Rekomendacje do przyszłych badań	38
4.3	Ograniczenia badań	39
4.4	Ostateczne wnioski	39
	Bibliografia	41
	Spis załączników	43

1 Wprowadzenie

1.1 Tło i motywacja

Wprowadzenie metod zmiennej metryki (inaczej quasi-newtonowskich) w połowie lat 50. XX wieku stanowiło rewolucyjne osiągnięcie w dziedzinie optymalizacji ciągłej bez ograniczeń. Wykorzystanie iteracyjnie poprawianej aproksymacji hesjanu funkcji celu umożliwiło osiągnięcie ponadliniowej zbieżności przy użyciu jedynie informacji gradientowej, czyniąc metody quasi-newtonowskie domyślnym wyborem w wielu praktycznych zadaniach optymalizacji nieliniowej [1].

Zadaniem metod optymalizacji lokalnej, w tym metod zmiennej metryki, jest znalezienie minimum lokalnego, a w przypadku funkcji wielomodalnej nie ma gwarancji, że jest ono jednocześnie globalne. Niska efektywność metod lokalnych w zadaniach wielomodalnych stanowiła motywację do rozwoju metod optymalizacji globalnej, charakteryzujących się zdolnością do opuszczania minimów lokalnych [2].

Zwiększona odporność na utykanie w lokalnych minimach przejawiana przez metody globalne wiąże się ze zwiększonym nakładem obliczeniowym w porównaniu do metod lokalnych. W celu wykorzystania zalet obu grup, jednocześnie niwelując ich słabości, powstała klasa algorytmów hybrydowych, sprzęgających te podejścia. Rozwiązania hybrydowe mają na celu osiągnięcie równowagi między eksploracją przestrzeni przeszukiwań a eksploatacją obiecujących jej obszarów [3].

Algorytm *Covariance Matrix Adaptation Evolution Strategy* (CMA-ES) stanowi dziś jedną z najefektywniejszych metod optymalizacji globalnej źle uwarunkowanych zadań w przestrzeniach o co najwyżej kilkuset wymiarach, co odzwierciedlają wyniki benchmarków porównawczych [4]. Na przestrzeni lat zaproponowano wiele wariantów i modyfikacji usprawniających jego efektywność w określonych klasach problemów [5–7].

W miarę postępu optymalizacji i koncentracji poszukiwań CMA-ES w otoczeniu pojedynczego minimum, charakter zadania ulega zmianie. Problem globalnej eksploracji przestrzeni poszukiwań stopniowo sprowadza się do zadania lokalnego przeszukiwania w pobliżu punktu optymalnego. W takiej sytuacji naturalnym punktem odniesienia stają się metody optymalizacji lokalnej, w szczególności metody zmiennej metryki, które zostały zaprojektowane z myślą o szybkim i dokładnym wyznaczeniu pojedynczego minimum. Stanowi to motywację do weryfikacji możliwości poprawy efektywności algorytmu CMA-ES poprzez połączenie go z metodą quasi-newtonowską.

1.2 Cel i hipotezy badawcze

Celem pracy jest zbadanie zwiększenia efektywności CMA-ES w zadaniu wielowymiarowej optymalizacji ciągłej przez hybrydyzację z algorytmem *Broyden-Fletcher-Goldfarb-Shanno* (BFGS). Proponowane połączenie algorytmów polega na okresowym uruchamianiu BFGS podczas działania CMA-ES z elementem jednostronnej kooperacji między algorytmami - BFGS uruchamiany jest w aktualnym punkcie środkowym populacji CMA-ES z początkowym przybliżeniem hesjanu funkcji celu równym znormalizowanej macierzy kowariancji

opisującej rozkład prawdopodobieństwa tej populacji. Po ukończeniu działania BFGS, CMA-ES kontynuuje optymalizację ze stanem sprzed uruchomienia BFGS.

Postawione są trzy hipotezy badawcze:

1. W przypadku optymalizacji funkcji kwadratowej, wraz z czasem działania algorytmu CMA-ES, macierz kowariancji opisująca rozkład prawdopodobieństwa jego populacji stanowi coraz dokładniejsze przybliżenie odwrotności hesjanu funkcji celu.
2. Możliwe jest przyspieszenie działania algorytmu BFGS poprzez inicjację go przy pomocy macierzy stanowiącej przybliżenie odwrotności hesjanu funkcji celu zamiast macierzy jednostkowej, stosowanej w domyślnym wariancie algorytmu. Zastosowanie macierzy kowariancji CMA-ES jako początkowego przybliżenia odwrotności hesjanu funkcji celu może skutkować przyspieszeniem działania BFGS względem wariantu domyślnego.
3. Hybrydyzacja algorytmów CMA-ES i BFGS może prowadzić do zwiększenia efektywności w porównaniu z oboma z tych algorytmów stosowanymi osobno. Efektywność rozumiana jest jako zarówno jakość wyznaczanych rozwiązań, jak i tempo ich wyznaczania.

2 Przegląd literatury

2.1 Algorytm CMA-ES

CMA-ES (*Covariance Matrix Adaptation Evolution Strategy*) zaproponowany przez N. Hansena [8] jest jednym z najskuteczniejszych bezgradientowych algorytmów w zadaniach wysokowymiarowej optymalizacji ciągłej. Algorytm 1 przedstawia pełny schemat działania CMA-ES.

Algorytm 1. Algorytm CMA-ES. Symbole objaśnione w dalszej części tekstu.

1 **Ustawienie parametrów**

| ustawienie λ , $w_{i=1\dots\lambda}$, c_m , c_σ , d_σ , c_c , c_1 , c_μ

2 **Inicjacja**

| ścieżki ewolucji: $\mathbf{p}_\sigma = \mathbf{0}$, $\mathbf{p}_c = \mathbf{0}$

| macierz kowariancji: $\mathbf{C} = \mathbf{I}$

| liczniki iteracji i ewaluacji funkcji celu: $g = 0$, $n_{\text{eval}} = 0$

| średnia rozkładu: $\mathbf{m} \in \mathbb{R}^n$

| rozmiar kroku: $\sigma > 0$

| log wygenerowanych rozwiązań: $L = \{\}$

3 **Dopóki nie spełniono kryterium zatrzymania:**

| $g \leftarrow g + 1$

| **Próbkowanie nowej populacji dla $k = 1, \dots, \lambda$ (równanie 2)**

4 | $\mathbf{z}_k \sim N(\mathbf{0}, \mathbf{I})$

5 | $\mathbf{y}_k = \mathbf{E}\sqrt{\Lambda}\mathbf{z}_k \sim N(\mathbf{0}, \mathbf{C})$

6 | $\mathbf{x}_k = \mathbf{m} + \sigma\mathbf{y}_k \sim N(\mathbf{m}, \sigma^2\mathbf{C})$

7 | $L \leftarrow L \cup \mathbf{x}_k$

| **Selekcja i rekombinacja**

8 | $\langle \mathbf{y} \rangle_w = \sum_{i=1}^\mu w_i \mathbf{y}_{i:\lambda}$

9 | | gdzie $\sum_{i=1}^\mu w_i = 1$ i $w_i > 0$ dla $i = 1 \dots \mu$

10 | aktualizacja średniej:

11 | | $\mathbf{m} \leftarrow \mathbf{m} + c_m \sigma \langle \mathbf{y} \rangle_w$

12 | aktualizacja licznika ewaluacji:

13 | | $n_{\text{eval}} \leftarrow n_{\text{eval}} + \lambda$

| **Sterowanie rozmiarem kroku**

14 | obliczenie współczynnika skalującego

15 | | $\mu_{\text{eff}} = \left(\sum_{i=1}^\mu w_i^2 \right)^{-1}$

16 | aktualizacja skumulowanej ścieżki (równanie 6):

17 | | $\mathbf{p}_\sigma \leftarrow (1 - c_\sigma)\mathbf{p}_\sigma + \sqrt{c_\sigma(2 - c_\sigma)}\mu_{\text{eff}}^{-\frac{1}{2}}\langle \mathbf{y} \rangle_w$

18 | aktualizacja rozmiaru kroku (równanie 5):

19 | | $\sigma \leftarrow \sigma \cdot \exp\left(\left(\frac{c_\sigma}{d_\sigma}\right)\left(\frac{\|\mathbf{p}_\sigma\|}{E(\|N(\mathbf{0}, \mathbf{I})\|)}\right) - 1\right)$

| **Adaptacja macierzy kowariancji**

20 | aktualizacja skumulowanej ścieżki (równanie 4):

21 | | $\mathbf{p}_c \leftarrow (1 - c_c)\mathbf{p}_c + h_\sigma \sqrt{c_c(2 - c_c)}\mu_{\text{eff}}\langle \mathbf{y} \rangle_w$

22 | aktualizacja macierzy kowariancji (równanie 3)¹:

23 | | $\mathbf{C} \leftarrow (1 + c_1\delta(h_\sigma) - c_1 - c_\mu \sum w_j)\mathbf{C} + c_1\mathbf{p}_c\mathbf{p}_c^T + c_\mu \sum_{i=1}^\lambda w_i \mathbf{y}_{i:\lambda} \mathbf{y}_{i:\lambda}^T$

¹Parametr δ jest współczynnikiem skalującym, aplikowanym w przypadku, gdy $h_\sigma = 0$.

Próbkowanie populacji

W przeciwieństwie do klasycznych algorytmów ewolucyjnych [9], CMA-ES nie operuje bezpośrednio na skończonej populacji jako części stanu, zamiast tego skupiając się na adaptacji rozkładu prawdopodobieństwa, z którego jest ona próbkowana. Próbkowanie populacji odbywa się zgodnie z rozkładem normalnym $N(\mathbf{m}, \sigma^2 \mathbf{C})$, gdzie punkt $\mathbf{m}$ odpowiada za jej położenie w przestrzeni przeszukiwań, macierz kowariancji $\mathbf{C}$ za jej „wzorec rozproszenia”, a parametr σ służy za skalę jej rozproszenia, stanowiąc odpowiednik siły operatora mutacji w klasycznych algorytmach ewolucyjnych.

Populacja algorytmu w iteracji $g + 1$ zawiera punkty $\mathbf{x}_k^{g+1}$ zdefiniowane następująco:

$$\mathbf{x}_k^{(g+1)} \sim \mathbf{m}^{(g)} + \sigma^{(g)} N(0, \mathbf{C}^{(g)}) \quad \text{dla } k = 1, \dots, \lambda \quad (1)$$

gdzie λ - rozmiar populacji.

Próbkowanie populacji opisanej rozkładem normalnym z niediagonalną macierzą $\mathbf{C}$ wymaga rozłożenia $\mathbf{C}$ na wartości i wektory własne, co stanowi główne ograniczenie skalowalności CMA-ES powyżej kilkuset wymiarów². Znając rozkład $\mathbf{C} = \mathbf{E}\mathbf{\Lambda}\mathbf{E}^T$, gdzie $\mathbf{E}$ jest macierzą wektorów własnych $\mathbf{C}$, a $\mathbf{\Lambda}$ diagonalną macierzą wartości własnych, próbkowanie przeprowadzane jest następująco:

$$\begin{aligned} \mathbf{z}_k &\sim N(0, \mathbf{I}) \\ \mathbf{y}_k &= \mathbf{E}\sqrt{\mathbf{\Lambda}}\mathbf{z}_k \sim N(0, \mathbf{C}) \\ \mathbf{x}_k &= \mathbf{m} + \sigma\mathbf{y}_k \sim N(\mathbf{m}, \sigma^2\mathbf{C}) \end{aligned} \quad (2)$$

Adaptacja macierzy kowariancji

Macierz kowariancji w iteracji $g + 1$ jest sumą ważoną trzech składników zgodnie ze wzorem:

$$\begin{aligned} \mathbf{C}^{(g+1)} &= (1 - c_1 - c_\mu \sum w_j) \mathbf{C}^{(g)} + \\ &\quad c_\mu \sum_{i=1}^{\lambda} w_i \mathbf{y}_{i:\lambda}^{(g+1)} \left(\mathbf{y}_{i:\lambda}^{(g+1)} \right)^T + \\ &\quad c_1 \mathbf{p}_c^{(g+1)} \mathbf{p}_c^{(g+1)T} \end{aligned} \quad (3)$$

Pierwszy składnik odpowiada macierzy kowariancji aktualnej populacji algorytmu. W praktyce, jego waga $(1 - c_1 - c_\mu \sum w_j)$ jest często zerowa lub bliska zera [10].

Składnik $c_\mu \sum_{i=1}^{\lambda} w_i \mathbf{y}_{i:\lambda}^{(g+1)} \left(\mathbf{y}_{i:\lambda}^{(g+1)} \right)^T$ odpowiada za aktualizację macierzy kowariancji na podstawie jakości populacji spróbkowanej w bieżącej iteracji algorytmu. Wektor $\mathbf{y}_{i:\lambda}$ jest znormalizowanym wektorem różnicowym i -tego najlepszego punktu obecnej populacji (por. równanie 2). Wektory różnicowe populacji ulegają ważonemu uśrednieniu, na ogół niezerowe wagi przyjmowane są dla μ najlepszych punktów obecnej populacji.

Trzeci składnik opiera się na iloczynie zewnętrznym wektora $\mathbf{p}_c$ nazwanego przez N. Hansena „skumulowaną ścieżką” dotychczasowej ewolucji populacji [10]. Parametr c_1 stanowi

²Rozkład macierzy o wymiarach $d \times d$ na wektory i wartości własne obarczony jest złożonością obliczeniową rzędu $O(d^3)$.

wagę skumulowanych aktualizacji macierzy kowariancji, obniżenie jego wartości oznacza zmniejszenie „pamiętliwości” algorytmu.

Współczynnik p_c jest zdefiniowany następująco:

$$p_c^{(g+1)} = (1 - c_c)p_c + h_\sigma \sqrt{c_c(2 - c_c)\mu_{\text{eff}}}\langle y \rangle_w \quad (4)$$

gdzie c_c jest parametrem algorytmu, a $\langle y \rangle_w$ jest ważoną sumą μ wektorów y odpowiadających najlepszym punktom populacji. μ_{eff} oraz h_σ są współczynnikami skalującymi, których szczegółowe wyprowadzenie znajduje się w [10].

Algorytm CSA - reguła aktualizacji σ

Algorytm adaptacji kroku CSA jest elementem niezależnym od adaptacji macierzy kowariancji. Podczas gdy adaptacja macierzy kowariancji odpowiada za kształt rozkładu populacji, CSA zajmuje się aktualizacją globalnego rozmiaru kroku.


Rozmiar kroku σ w iteracji $g + 1$ zdefiniowany jest następująco:

$$\sigma^{(g+1)} = \sigma^{(g)} \exp \left(\left(\frac{c_\sigma}{d_\sigma} \right) \left(\frac{\|p_\sigma^{(g+1)}\|}{E(\|N(0, I)\|)} - 1 \right) \right) \quad (5)$$

gdzie c_σ i d_σ są parametrami algorytmu, a p_σ jest współczynnikiem analogicznym do p_c stosowanym do sterowania rozmiarem kroku, zdefiniowanym następująco:

$$p_\sigma^{(g+1)} = (1 - c_\sigma)p_\sigma^{(g)} + \sqrt{c_\sigma(2 - c_\sigma)\mu_{\text{eff}}}C^{-\frac{1}{2}}\langle y \rangle_w \quad (6)$$

Intuicja leżąca za aktualizacją rozmiaru kroku jest następująca: jeżeli przesunięcia punktu m w poprzednich iteracjach są zgodne co do kierunku, rozmiar kroku powinien być wydłużony. Jeżeli podejmowane kroki nie są zgodne co do kierunku, może być to interpretowane jako sygnał poruszania się populacji wokół lokalnego optimum. W takiej sytuacji stosowne jest skrócenie kroku. Wysoka wartość parametru σ związana jest ze wzmożoną eksploracją przestrzeni przeszukiwań lub ruchem wzdłuż rozległego zbocza, a niska - ze wzmożoną eksploatacją obiecującego jej obszaru i próbą dokładnego zbliżenia się do optimum.



Rysunek 1. Intuicja stojąca za regułą CSA. Pierwszy przypadek - należy skrócić rozmiar kroku, trzeci - należy go wydłużyć. Źródło: N. Hansen, The CMA Evolution Strategy: A Tutorial [10]

CMA-ES - dopasowanie konturu a hesjan funkcji celu

Macierz kowariancji rozkładu populacji algorytmu CMA-ES charakteryzuje się własnością polegającą na dopasowaniu poziomicy funkcji gęstości rozkładu populacji do lokalnej geometrii funkcji celu („*contour matching*”). W [10] Hansen twierdzi, że adaptacja macierzy kowariancji CMA-ES jest analogiczna do wyznaczania odwrotności hesjanu funkcji celu w metodach zmiennej metryki.

Istnieją empiryczne wyniki wskazujące na istnienie tej zależności w praktycznych zastosowaniach algorytmu, przedstawione m.in. w [11]. W literaturze brak jest jednak ścisłego dowodu dla pełnej postaci algorytmu CMA-ES; analogiczny rezultat wykazano natomiast dla algorytmu NGD, powiązanego z wariantami z klasy *rank- μ* CMA-ES ([12]).

CMA-ES - działanie w obecności ograniczeń kosztowych

Pierwotnie, algorytm CMA-ES nie był projektowany z myślą o optymalizacji w przestrzeni z ograniczeniami kosztowymi, możliwe jest jednak stosowanie metod uwzględnienia ograniczeń, które można podzielić na trzy grupy:

1. Modyfikacja (odbijanie, rzutowanie na ograniczenia) lub ponowne próbkowanie punktu niespełniającego ograniczeń kosztowych;
2. Modyfikacja funkcji celu przez dodanie czynnika kary poza ograniczeniami kosztowymi;
3. Wykorzystanie informacji o wektorze średniej populacji $\mathbf{m}$ w celu przeprowadzenia procedury naprawczej, przykładowo zastąpienie wartości i -tego elementu wektora rozwiązania leżącego poza ograniczeniami do odpowiadającą mu wartością i -tego elementu wektora $\mathbf{m}$;

Szczegółowe porównanie wariantów uwzględniania ograniczeń kosztowych w algorytmie CMA-ES zaprezentowane jest w [13]. Praca ta wskazuje na różnice w efektywności algorytmu związane z poszczególnymi metodami uwzględniania ograniczeń.

CMA-ES jako część optymalizatora hybrydowego

Motyw łączenia globalnych i lokalnych metod optymalizacji pojawia się często w algorytmach zgłaszanych do konkursów metod optymalizacji. Przykładem takiego sprzężenia jest algorytm iCMAES-ILS, łączący wariant CMA-ES o zmiennym rozmiarze populacji (IPOP-CMA-ES) z metodą *Iterated Local Search* (ILS). Podczas początkowego etapu optymalizacji algorytmy konkurują ze sobą, następnie do kontynuacji procesu wybierany jest ten, który osiągnął lepszy wynik przy ograniczonym budżecie obliczeniowym. Algorytm zawiera także element kooperacji między składowymi polegający na przekazywaniu najlepszego rozwiązania osiągniętego przez IPOP-CMA-ES jako punktu startowego metody ILS. Metoda iCMAES-ILS osiągnęła lepsze wyniki od klasycznego IPOP-CMA-ES w zadaniach optymalizacji funkcji z zestawu CEC2013 [6].

Podobnym przykładem połączenia algorytmów opartego na rywalizacji z elementem początkowej współpracy jest LSHADE-SPACMA, stanowiący hybrydę ewolucji różnicowej w wariancie LSHADE oraz zmodyfikowanego CMA-ES. Początkowo algorytmy generują tę samą liczbę potomstwa na podstawie aktualnej populacji. Zależnie od tego, która ze strategii generacji przynosi większą poprawę wartości funkcji celu, waga odpowiadającego za nią algorytmu jest zwiększana, umożliwiając mu generację większej liczby potomków. Opisane

podejście osiągnęło lepsze wyniki na zestawie CEC2013 od klasycznego algorytmu LSHADE [14].

Innym przykładem sprzężania metod optymalizacji jest algorytm jSO_CMA-ES_LBFGS, stanowiący połączenie algorytmu ewolucji różnicowej używanego do eksploracji przestrzeni przeszukiwań z metodami CMA-ES oraz LBFGS stosowanymi jako optymalizatory lokalne. W badaniach przeprowadzonych w [15] algorytm wykazał się wyższą skutecznością od klasycznej ewolucji różnicowej.

Przedstawione algorytmy ilustrują różne sposoby hybrydyzacji CMA-ES z innymi metodami, obejmujące zarówno schematy rywalizacji, jak i współpracy oraz wykorzystanie optymalizatorów lokalnych w końcowej fazie działania.

2.2 Algorytm BFGS

Algorytm BFGS jest najpopularniejszym algorytmem zmiennej metryki w zadaniach optymalizacji bez ograniczeń, wywodzącym się z czterech niezależnych prac z 1970 roku [16–19].

Zamiast obarczonej złożonością obliczeniową $O(d^3)$, gdzie d jest wymiarem przestrzeni przeszukiwań, procedury obliczania odwrotności hesjanu funkcji celu w każdej iteracji na wzór metody Newtona, BFGS wykorzystuje macierz $\mathbf{B}$ służącą za jej przybliżenie. W każdej iteracji ulega ona aktualizacji rzędu drugiego (ang. *rank-2 update*), spełniającej warunek siecznych. Szczegółowe objaśnienie adaptacji przybliżenia macierzy $\mathbf{B}$ znajduje się w [1]. Uniknięcie obliczania odwrotności d -wymiarowej macierzy w każdej iteracji skutkuje obniżeniem złożoności obliczeniowej algorytmu do $O(d^2)$. Metoda BFGS wykazuje nadliniową zbieżność lokalną przy spełnieniu standardowych założeń odnośnie funkcji celu w metodach quasi-newtonowskich.

Algorytm 2. Algorytm BFGS. Symbole: g - numer iteracji, f - optymalizowana funkcja, $\mathbf{x}_g$ - rozwiązanie w g -tej iteracji, $\nabla f_g = \nabla f(\mathbf{x}_g)$, $\mathbf{B}_g$ - przybliżenie odwrotności hesjanu f w g -tej iteracji, ε - tolerancja (kryterium zbieżności).

```

1 Inicjacja  $\mathbf{B}_0 = \mathbf{I}$ ,  $\varepsilon > 0$ ,  $g = 0$ 
2 Dopóki  $\|\nabla f_g\| > \varepsilon$ 
   Obliczenie kierunku przeszukiwania
3    $\mathbf{p}_g = -\mathbf{B}_g \nabla f_g$ 
4    $\alpha_g \leftarrow \text{line\_search}(\mathbf{x}_g, \mathbf{p}_g)$ 
5    $\mathbf{x}_{g+1} = \mathbf{x}_g + \alpha_g \mathbf{p}_g$ 
6   Adaptacja macierzy  $\mathbf{B}_g$ 
7    $g \leftarrow g + 1$ 
```

Złożoność obliczeniowa rzędu $O(d^2)$ ogranicza możliwość stosowania BFGS w problemach o wysokiej wymiarowości. W [20] R. Byrd oraz współautorzy zaproponowali metodę L-BFGS-B, wykorzystującą oszczędną pamięciowo, mniej dokładną reprezentację macierzy $\mathbf{B}$. L-BFGS-B wspiera ponadto działanie w obecności ograniczeń kostkowych.

W algorytmach zgłaszanych do konkursów optymalizacji CEC (*Congress on Evolutionary Computation*) częstą praktyką jest zakończenie fazy globalnej optymalizacji procedurą lokal-

ną, najczęściej typu quasi-newtonowskiego (BFGS lub L-BFGS-B), w celu doprecyzowania najlepszego znalezionej rozwiązania (np. [21, 22]).

2.3 Porównywanie metod optymalizacji

2.3.1 Krzywe zbieżności

Krzywa zbieżności algorytmu optymalizacyjnego opisuje zależność między najlepszym dotychczasowym rozwiązaniem a liczbą wykorzystanych ewaluacji funkcji celu. Zbieżność algorytmu w tym kontekście rozumiana jest jako empiryczna miara tempa poprawy wyniku optymalizacji.

Krzywe zbieżności stanowią podstawowe narzędzie do porównywania efektywności optymalizatorów, mają jednak szereg ograniczeń. W przypadku algorytmów deterministycznych, mogą się one znacząco różnić w zależności od punktu startowego i ustawień algorytmu. W przypadku algorytmów niedeterministycznych, np. CMA-ES, kolejnym czynnikiem wpływającym na postać krzywej jest wartość ziarna generatora liczb losowych używanego wewnątrz algorytmu. W związku z tym, pojedyncze krzywe zbieżności zawierają zbyt mało informacji, aby świadczyć o ogólnej efektywności optymalizatora. Zazwyczaj uśrednia się krzywe z wielu uruchomień algorytmu, co daje bardziej miarodajną metrykę jego efektywności, wiąże się to jednak z ryzykiem utraty istotnych informacji ze względu na wpływ przypadków brzegowych na wartość średniej.

Uśrednianie krzywych zbieżności z wielu uruchomień na różnych funkcjach celu nie jest praktykowane ze względu na utratę informacji o jakości rozwiązania w kontekście skali i charakterystyki poszczególnych funkcji, gdyż ich wartości mogą różnić się o rzędy wielkości i nie posiadają wspólnej, sensownej interpretacji ilościowej.

2.3.2 Krzywe ECDF

Ze statystycznego punktu widzenia, pojęcie empirycznej dystrybuanty rozkładu prawdopodobieństwa oznacza przybliżenie dystrybuanty na podstawie próby z tego rozkładu o skończonej wielkości. W kontekście oceny skuteczności optymalizatora możliwe jest wyznaczenie empirycznej dystrybuanty osiąganych przez niego wartości funkcji celu w zależności od zadanego budżetu ewaluacji. Wartość tak określonej krzywej ECDF (*Empirical Cumulative Distribution Function*) dla budżetu t opisana jest następująco:

$$\text{ECDF}(t) = \frac{1}{kn} \sum_{i=1}^n \sum_{j=1}^k \mathbb{1}(\mathbf{x}_i(t) \leq q_j) \quad (7)$$

gdzie:

- n - liczba uruchomień algorytmu
- $\mathbf{x}_i$ - szereg najlepszych dotychczasowych osiągniętych wartości funkcji celu w i -tym uruchomieniu
- k - liczba wyznaczonych poziomów satysfakcji
- q_j - j -ty poziom satysfakcji

Punkt (t, y) oznacza, że uśredniając po n uruchomieniach, po t ewaluacjach funkcji celu algorytm osiągnął średnio ułamek y zdefiniowanych poziomów satysfakcji.

Poziomy satysfakcji wyznaczane są zazwyczaj jako równomiernie rozmieszczone w skali logarytmicznej wartości z zakresu $[f_{\text{worst}}, f_{\text{target}}]$, gdzie f_{worst} - najwyższa wartość błędu³ zaobserwowana pośród wszystkich uruchomień algorytmu, f_{target} - przyjęty poziom dokładności numerycznej uznawany za wystarczający do identyfikacji optimum globalnego.

W przeciwieństwie do krzywych zbieżności, oś Y krzywych ECDF jest znormalizowana do przedziału $[0, 1]$, co umożliwia sensowne agregowanie i porównywanie wyników pomiędzy różnymi funkcjami celu o odmiennych skalach wartości.

Uznanie wyższości optymalizatora A nad B na podstawie analizy krzywych ECDF możliwe jest wyłącznie wtedy, gdy $\forall_{t \in T} \text{ECDF}_A(t) \geq \text{ECDF}_B(t)$ ⁴. Oznacza to, że nie istnieje budżet ewaluacji w zadanym zbiorze, dla którego optymalizator B osiągnął więcej poziomów satysfakcji niż optymalizator A.

Możliwe jest zastosowanie miary pola pod krzywą ECDF jako metryki efektywności optymalizatora. Wyższe pole interpretowalne jest jako wyższa średnia jakość rozwiązania w rozważanym zakresie budżetów. Warto jednak zauważyć, że wartość tego pola zależy od sposobu ustalania poziomów satysfakcji oraz zbioru progów budżetowych (np. wyznaczanie ich jako zbioru liczb równo oddzielonych w skali liniowej a logarytmicznej).

2.3.3 Zestawy funkcji benchmarkowych i konkurs CEC

Aby porównać efektywność optymalizatorów, pożądane jest przeprowadzenie porównania na wzorcowej grupie zadań mających źródło w praktycznych zastosowaniach lub je naśladujących. Najczęściej wykorzystywanymi na potrzeby analizy porównawczej przykładami takich zbiorów zadań ciągłej optymalizacji globalnej z ograniczeniami kosztowymi są BBOB [23] udostępniany w ramach platformy COCO [24] lub zestawy funkcji związane z corocznymi zawodami optymalizatorów przeprowadzanymi w ramach konferencji CEC (*Congress on Evolutionary Computation*). Wykorzystanie takich zestawów zapewnia porównywalność wyników pomiędzy pracami oraz ogranicza wpływ doboru funkcji testowych na końcowe wnioski.

2.3.4 Problemy w porównywaniu metod optymalizacji

Porównywanie optymalizatorów samo w sobie stanowi nietrywialne zadanie. Zgodnie z *No Free Lunch Theorem*, nie jest możliwe opracowanie uniwersalnie najefektywniejszego optymalizatora, a osiągnięcie przez dany algorytm dobrych wyników w rozwiązywaniu zadań ze zbioru X nie musi świadczyć o podobnym stopniu efektywności na zbiorze Y. W związku z tym, wybór zestawu benchmarkowego oraz metryk porównawczych ma znaczący wpływ na wyniki poszczególnych algorytmów w danym porównaniu [25]. Wyniki szeroko zakrojonego badania porównawczego pokazują, że rankingi optymalizatorów silnie zależą od doboru zestawu benchmarkowego oraz przyjętego budżetu ewaluacji - algorytmy osiągające

³Błąd definiowany jest jako różnica między osiągniętą wartością funkcji celu a wartością optimum globalnego

⁴Z założeniem, że krzywe wyznaczono dla tych samych zbiorów budżetów ewaluacji (oś X) oraz poziomów satysfakcji (progi osi Y).

najlepsze wyniki na nowszych zestawach (np. CEC2020) często wykazują przeciętną lub słabą skuteczność na starszych benchmarkach (np. CEC2011) lub na zadaniach o charakterze praktycznym [26].

2.4 Środowiska implementacji

Dziedzina badań nad algorytmami optymalizacyjnymi charakteryzuje się niskim poziomem ustandaryzowania narzędzi, co niesie ze sobą szereg problemów. Zdarza się, że różne implementacje tego samego algorytmu charakteryzują się zupełnie odmiennymi wynikami, mimo że zostały napisane przez tego samego autora [27]. Utrudnia to porównywanie proponowanych algorytmów z wersjami wzorcowymi, ponieważ zależnie od wybranej implementacji, wyniki porównania mogą się znacząco różnić. W tej sekcji pracy przedstawione zostaną decyzje dotyczące wyborów poszczególnych zależności i stojące za nimi motywacje.

Implementacja eksperymentów przeprowadzonych w ramach pracy wykonana została w Pythonie, który współcześnie jest *de facto* standardowym środowiskiem eksperymentalnym w badaniach nad algorytmami optymalizacyjnymi, przy jednoczesnym istnieniu alternatywnych implementacji w m.in. C++ oraz R.

Wykorzystaną implementacją algorytmu CMA-ES jest zaproponowana w [28] biblioteka `cmaes`, cechująca się minimalizmem i wysokim stopniem czytelności kodu. Istotnym przy wyborze implementacji CMA-ES aspektem był brak nadprogramowych, nieudokumentowanych mechanizmów wychodzących poza bazowy wariant algorytmu, które mogłyby mieć wpływ na otrzymane wyniki badań, co stanowiło motywację do odejścia od najszerzej stosowanej biblioteki `pycma` autorstwa N. Hansena.

Wykorzystaną biblioteką implementującą funkcje z benchmarku CEC2017 jest `cecxx` autorstwa E. Warchulskiego. Stanowi ona alternatywę dla implementacji w C udostępnianych przez organizatorów konkursu, charakteryzujących się wyciekami pamięci oraz potrzebą odczytu danych z dysku przy każdej ewaluacji. Mimo niskiej popularności implementacji, wydawała się ona najrzetelniejszym spośród dostępnych rozwiązań ze względu na obszerny zbiór *fuzzingowych* testów zgodnościowych z oryginalnymi implementacjami. We wczesnych etapach badań używane były implementacje udostępnione w `opfunu`, stanowiącym największą bibliotekę funkcji benchmarkowych optymalizatorów w Pythonie, które wykazały się jednak brakiem zgodności z oryginalnymi funkcjami organizatorów konkursu⁵.

W badaniach wykorzystano implementację BFGS z modułu `scipy.minimize` stanowiącą standardowy wybór w Pythonowym środowisku.

W kwestii środowiska służącego do zarządzania eksperymentami i zapewniającego ich reprodukowalność, najszerzej rozpowszechniona jest biblioteka `COCO` [24] autorstwa N. Hansena. Ze względu na przekrojowy zakres badań oraz potrzebę zbierania niestandardowych metryk podczas procesu optymalizacji, nie została ona wykorzystana w pracy na rzecz własnej implementacji.

⁵Wszystkie wyniki otrzymane przy użyciu `opfunu` zostały wygenerowane ponownie z wykorzystaniem `cecxx`.

3 Przeprowadzone badania

3.0.1 Przyjęte ustawienia algorytmów

Przyjęto rozmiar populacji CMA-ES równy $4 \cdot d$. Początkowe położenie punktu środkowego populacji $\mathbf{m}$ generowane było zgodnie z rozkładem jednostajnym $U[-100, 100]^d$. Punkt startowy algorytmu BFGS wybierano analogicznie. Pozostałe parametry oraz ustawienia początkowe nie były modyfikowane względem domyślnych wartości w wykorzystywanych implementacjach.

3.0.2 Kryteria zatrzymania algorytmów

Tabele 1 i 2 zawierają informacje dotyczące obranych kryteriów zatrzymania dla algorytmów.

Tabela 1. Kryteria zatrzymania algorytmu CMA-ES w przeprowadzonych badaniach

Kryterium zatrzymania CMA-ES	Wartość
Minimalna różnica między maksymalną i minimalną wartością funkcji celu w wylosowanej populacji	10^{-9}
Maksymalna liczba ewaluacji funkcji celu przed zatrzymaniem algorytmu	$10^4 \cdot d$

Tabela 2. Kryteria zatrzymania algorytmu BFGS w przeprowadzonych badaniach

Kryterium zatrzymania BFGS	Wartość
Minimalna wartość gradientu w punkcie x_n , poniżej której następuje zatrzymanie algorytmu	10^{-8}
Maksymalna liczba ewaluacji funkcji celu przed zatrzymaniem algorytmu	Brak, o ile nie jest uruchamiany jako składowa optymalizatora z budżetem

Ograniczenia kostkowe przestrzeni przeszukiwań

Uwzględnianie ograniczeń kostkowych w algorytmie CMA-ES przeprowadzano w lamarkowskim wariancie odbijania rozwiązań do obszaru dopuszczalnego.

Próba ewaluacji optymalizowanej funkcji poza obszarem dopuszczalnym przez BFGS skutkowałą przerwaniem działania optymalizatora i zwróceniem jako wyniku najlepszej uzyskanej do tego momentu wartości.

3.1 Badanie zbieżności macierzy kowariancji algorytmu CMA-ES do odwrotności hesjanu funkcji celu

3.1.1 Cel badania

Zgodnie z [10] i [12], jeśli optymalizowana funkcja celu jest funkcją kwadratową, algorytm CMA-ES powinien po pewnym czasie dojść do sytuacji, w której macierz $\mathbf{C}$ jest przybliżeniem odwrotności hesjanu optymalizowanej funkcji z dokładnością do skali. Celem badania jest weryfikacja tego efektu i zbadanie jego tempa.

Funkcja SDP


Funkcja nazywana na dalsze potrzeby pracy SDP (ang. *Sum of different powers*) wyrażona jest wzorem

$$f(\mathbf{x}) = \sum_{i=0}^{d-1} 10^{6 \frac{i}{d-1}} x_i^2 \quad (8)$$

Funkcja SDP jest kwadratowa oraz separowalna. Odwrotność jej hesjanu jest macierzą diagonalną, gdzie wyraz na przekątnej w i -tym wierszu ma postać

$$H_{ii}^{-1} = \frac{1}{2} \cdot 10^{-6 \frac{i}{d-1}} \quad (9)$$

Funkcja SDP charakteryzuje się podłużną, wąską doliną. Wyznaczenie globalnego optimum z wysoką precyzją bywa wymagającym zadaniem ze względu na bardzo niskie wartości gradientu względem zmiennych x_i dla i bliskich zera. Rysunek 2 przedstawia poziomice funkcji SDP w dwóch wymiarach.



Rysunek 2. Wykres konturowy funkcji SDP w 2 wymiarach. Poziomice mają kształt elipsy, różnica gradientów w wymiarach x_1 i x_2 jest jednak zbyt znaczna, aby było to widoczne na rysunku.

Definicja 1. Funkcja SDP**3.1.2 Metodyka**

Badanie zostało przeprowadzone w jednakowy sposób dla wymiarowości $d \in \{5, 10, 20, 50, 100\}$. Algorytm CMA-ES został 25-krotnie uruchomiony w losowych punktach startowych $\mathbf{m}_0 \sim U[-100, 100]^d$. W zależności od wymiarowości⁶, co k iteracji (por. tabela 3) zapisywane były informacje o najlepszej osiągniętej dotychczas wartości funkcji celu,

⁶W celu zmniejszenia wolumenów danych wynikowych

wartościach własnych macierzy $\mathbf{C}$ oraz wartości parametru σ . 25 zestawów tych wartości było następnie uśredniane. Analizie podlegają następujące metryki:

- zmiany wartości funkcji celu najlepszego znalezionej do tej pory punktu (krzywa zbieżności) jako krzywa referencyjna, pomagająca w interpretacji pozostałych wyników
- $\sigma_g \sqrt{\Lambda_{ii}(\mathbf{C}_g)}$ - wyrażenie odpowiadające długościom poszczególnych osi rozkładu⁷, gdzie $\Lambda_{ii}(\mathbf{C}_g)$ to i -ta wartość własna macierzy $\mathbf{C}_g$
- $\frac{\Lambda_{ii}(\mathbf{C}_g)}{\Lambda_{ii}(\mathbf{H}^{-1})}$ - proporcje odpowiadających sobie wartości własnych odwrotności hesjanu funkcji celu i wartości własnych macierzy $\mathbf{C}_g$

Tabela 3. Częstość zbierania danych dla poszczególnych wymiarowości (jednostka - iteracje CMA-ES)

Wymiarowość problemu	10	20	30	50	100	200
Interwał zapisu danych (k)	1	1	1	1	4	8


3.1.3 Analiza zbieżności macierzy kowariancji do odwrotności hesjanu funkcji celu w oparciu o krzywe zbieżności

Przykładowe krzywe zbieżności dla wybranych wymiarowości zostały ukazane na rysunku 3. Ukończenie optymalizacji następowało przed wyczerpaniem budżetu ewaluacji dla każdej z badanych wymiarowości. Wraz ze wzrostem liczby wymiarów, przebieg krzywej zbieżności wykazuje coraz wyraźniejszą tendencję do podziału na trzy etapy o różnym tempie spadku wartości funkcji SDP dla najlepszego dotychczasowego rozwiązania.


Pierwszym etapem jest relatywnie krótki początkowy okres szybkiej zbieżności, po którym następuje jej spowolnienie, szczególnie widoczne dla $d \in \{20, 100\}$. Następnie, po upływie znaczącej liczby iteracji, zależnej od wymiarowości ($d = 5$ - interwał ok. 10-80 iteracji, $d = 20$ - interwał ok. 10-220 iteracji, $d = 100$ - interwał ok. 100-1200 iteracji), tempo poprawy wyniku ponownie przyspiesza.

Interpretacja tych etapów w kontekście adaptacji macierzy kowariancji zostanie przedstawiona w dalszej części rozdziału dla kolejno niskiej, średniej i wysokiej wymiarowości problemu.


⁷Pojęcie długości osi rozkładu dotyczy długości osi elipsoid wyznaczonych przez poziomice funkcji gęstości rozkładu generującego punkty populacji; rozkład ten jest rozkładem normalnym z wartością oczekiwaną $\mathbf{m}_g$ oraz macierzą kowariancji $\sigma_g^2 \cdot \mathbf{C}_g$



Rysunek 3. Krzywe zbieżności algorytmu CMA-ES dla wybranych wymiarowości. Funkcja SDP. Czerwone proste służą wizualizacji poszczególnych etapów optymalizacji.




Rysunek 4. Długości poszczególnych osi rozkładu populacji. Funkcja SDP, 5 wymiarów.




Rysunek 5. Ilorazy odpowiadających wartości macierzy C i odwrotności hesjanu funkcji celu. Funkcja SDP, 5 wymiarów.

Rysunki 4 oraz 5 przedstawiają przebieg adaptacji macierzy kowariancji algorytmu w 5 wymiarach. Na ich podstawie można stwierdzić, że uzgodnienie macierzy C oraz odwrotności hesjanu następuje po około 60 iteracjach, po czym stosunek między długościami osi rozkładu populacji stabilizuje się, a każda z wartości stanowi z dokładnością do skali dobre przybliżenie swojego odpowiednika w odwrotności hesjanu funkcji celu. Zbieżność po osiągnięciu tego stanu zauważalnie przyspiesza względem wcześniejszych iteracji, jednak w mniejszym stopniu, niż dla wyższych wymiarowości (por. rysunek 3).



Rysunek 6. Zagregowane statystyki dotyczące ilorazów odpowiadających sobie wartości własnych macierzy kowariancji CMA-ES oraz odwrotności hesjanu funkcji celu w 20 wymiarach. Linia niebieska - wartość średnia, linia zielona - 75. centyl, linia pomarańczowa - 25. centyl ilorazów.




Rysunek 7. Zagregowane statystyki dotyczące ilorazów odpowiadających sobie wartości własnych macierzy kowariancji CMA-ES oraz odwrotności hesjanu funkcji celu w 100 wymiarach. Linia niebieska - wartość średnia, linia zielona - 75. centyl, linia pomarańczowa - 25. centyl ilorazów.

Rysunki 6 oraz 7 przedstawiają zagregowane statystyki dotyczące ilorazów odpowiadających sobie wartości własnych macierzy $\mathbf{C}$ oraz odwrotności hesjanu funkcji SDP w 20 i 100 wymiarach. Porównując je z krzywymi zbieżności ukazanymi na rysunku 3 można zauważyć, że zauważalne zbliżenie wartości 25. oraz 75. centyla do wartości średniej ilorazów jest skorelowane z przyspieszeniem zbieżności algorytmu. Ponadto, w obu przypadkach, różnica między wartościami 25. i 75. centyla ilorazów maleje wraz z liczbą iteracji, co sugeruje wzrost dokładności osiąganego przybliżenia odwrotności hesjanu.

Porównanie rysunków 6 i 7 zdaje się także wskazywać na osiągnięcie dokładniejszego przybliżenia odwrotności hesjanu funkcji SDP w 20 wymiarach niż w przypadku stuwymiarowym. Ze względu na logarytmiczną skalę osi Y jest to jednak jedynie wizualna interpretacja, niepozwalająca na sformułowanie dalszych wniosków ilościowych.

3.1.4 Porównanie z wynikami znanymi z literatury



Rysunek 8. Wyniki analogicznego badania na funkcji SDP przeprowadzonego przez N. Hansena. Źródło: N. Hansen, Covariance Matrix Adaptation Evolution Strategy (CMA-ES) - slajdy [11]

Badanie w formie podobnej do opisywanego przeprowadził dla funkcji SDP w 9 wymiarach N. Hansen [11]. Dla porównania, na rysunku 8 przedstawiono jego wyniki. Po około 4000 ewaluacji funkcji celu widoczne jest przyspieszenie tempa zmiany najlepszego znalezionej punktu (lewy panel, niebieska krzywa) oraz stabilizacja stosunków między długościami osi rozkładu populacji (prawy panel), co odpowiada zjawiskom zaobserwowanym na rysunkach 3 oraz 4. Warto zauważyć, że wyniki Hansena pochodzą przypuszczalnie z pojedynczego uruchomienia algorytmu, na co wskazuje „postrzępiona” charakterystyka krzywych. Ze względu na inną wymiarowość zadania oraz różnicę w rozmiarze populacji nie jest możliwe bezpośrednie porównanie tempa stabilizacji macierzy C , jednak zjawisko jest zauważalne w obu przypadkach.

3.1.5 Wnioski

Wyniki przeprowadzonego badania są zgodne ze spostrzeżeniami obecnymi w literaturze. Dla przypadku separowalnej funkcji kwadratowej istnieje empirycznie wykazana tendencja macierzy kowariancji algorytmu CMA-ES do zbieżności do odwrotności hesjanu funkcji celu z dokładnością do skali. W analizowanym przypadku okres intensywnej adaptacji macierzy kowariancji objawia się zmniejszeniem tempa zbieżności algorytmu. Następnie, po odpowiednio dokładnym przybliżeniu odwrotności hesjanu funkcji celu, zbieżność ulega przyspieszeniu.

3.2 Przyspieszenie zbieżności BFGS przy pomocy macierzy kowariancji z CMA-ES dla unimodalnej funkcji kwadratowej

3.2.1 Cel badania

Zgodnie z [1], macierz B_0 algorytmu BFGS może być inicjowana jako odwrotność numerycznie obliczonego hesjanu funkcji celu w punkcie startowym w celu lepszego dopasowania początkowego przybliżenia do rozwiązywanego zadania. Empirycznie wykazano, że dla

funkcji SDP macierz $\mathbf{C}$ algorytmu CMA-ES zbiega do odwrotności hesjanu z dokładnością do skali. Stanowi to motywację do zbadania, czy i w którym momencie przybliżenie to jest wystarczająco wierne, aby inicjacja z jego wykorzystaniem umożliwiła przyspieszenie zbieżności algorytmu BFGS w porównaniu do bazowego wariantu wykorzystującego macierz jednostkową. Ponadto, warte rozpatrzenia jest, czy wykorzystanie niedokładnego przybliżenia osiąganego na początkowym etapie działania CMA-ES może negatywnie wpłynąć na działanie algorytmu.

Porównane zostanie tempo zbieżności BFGS dla trzech wariantów początkowego przybliżenia hesjanu funkcji celu $\mathbf{B}_0$:

1. $\mathbf{B}_0 = \alpha \mathbf{I}$ - wariant podstawowy, inicjowany wartością jednostkową
2. $\mathbf{B}_0 = \alpha \mathbf{H}^{-1}$ - wariant „idealny”, inicjowany odwrotnością hesjanu funkcji celu
3. $\mathbf{B}_0 = \alpha \mathbf{C}_g$ - wariant inicjowany macierzą kowariancji algorytmu CMA-ES po jego g -tej iteracji

Parametr α jest współczynnikiem skalującym - wstępne badania algorytmu BFGS wykazały, że procedura optymalizacji kierunkowej jest wrażliwa na normę podawanej odwrotności hesjanu. Z tego względu rozważono dwie skale normalizacji macierzy $\mathbf{B}_0$ - niezależną od wymiaru ($\|\mathbf{B}_0\| = 1$) oraz dodatkowe zmniejszenie odpowiadające skalowaniu norm euklidesowych ($\|\mathbf{B}_0\| = d^{-\frac{1}{2}}$).

Można przypuszczać, że wariant inicjowany dokładną odwrotnością hesjanu funkcji celu wykaże się znacząco szybszą zbieżnością od klasycznego wariantu z macierzą jednostkową. Te dwa przypadki kontrolne stanowią punkty odniesienia dla proponowanej metody wykorzystującej macierz $\mathbf{C}$ algorytmu CMA-ES.

Powyższe konfiguracje rozważono dla dwóch sposobów wyznaczania punktu startowego BFGS:

1. $\mathbf{x}_0 \sim U[-100, 100]$
2. $\mathbf{x}_0 = \mathbf{m}_g$

Pierwszy z nich bada wyłącznie wpływ macierzy $\mathbf{B}_0$ na tempo zbieżności algorytmu, eliminując efekt bliskości punktu startowego względem optimum. Obranie losowego punktu startowego oznacza potencjalnie większy nakład obliczeń wymagany do wyznaczenia optimum⁸.

Drugi wariant odpowiada warunkom, w których algorytm BFGS wykorzystywany będzie jako składnik hybrydowego optymalizatora. Inicjacja w punkcie $\mathbf{m}_g$ pozwala zbadać łączny efekt bliskości do optimum oraz wartości $\mathbf{B}_0$ na tempo zbieżności algorytmu.

Porównanie dwóch wariantów wyznaczania punktu startowego umożliwia rozdzielenie wpływu jakości przybliżenia hesjanu od wpływu odległości punktu startowego od optimum globalnego oraz zbadanie interakcji tych czynników.

3.2.2 Metodyka

Badanie zostało przeprowadzone w ten sam sposób dla wymiarowości $d \in \{10, 20, 50, 100\}$. Analogicznie do poprzedniego rozdziału, optymalizacji podlegała funkcja SDP. Algorytm

⁸Zgodnie z definicją 1, hesjan funkcji SDP jest stały w $\mathbb{R}^n$, co pozwala na użycie tego samego przybliżenia niezależnie od punktu startowego.


CMA-ES został uruchomiony 25 razy. Co 20 iteracji zapisywano macierz C_g oraz wektor średni m_g , które następnie wykorzystywano do inicjacji algorytmu BFGS.

Po zebraniu potrzebnych danych, dla każdego spośród 25 ciągów (C_g, m_g) , uruchamiano 25 razy BFGS. W wariancie z losowym punktem x_0 wygenerowano jeden zestaw 25 punktów startowych, używany w każdej z grup. Na wyniki każdego wariantu składało się wobec tego łącznie 625 uruchomień BFGS.

Agregacja danych dotyczących zbieżności algorytmu BFGS przebiegała dwuetapowo - początkowo poddawane interpolacji na wspólnym zbiorze punktów i uśrednieniu były krzywe zbieżności BFGS w każdej z grup, następnie agregowano je na poziomie uruchomień CMA-ES, uzyskując końcowe krzywe omawiane w tym rozdziale.

3.2.3 Omówienie wyników badania

W pierwszej kolejności omówiony zostanie wariant badania, w którym algorytm BFGS rozpoczynał optymalizację w losowych punktach zbioru dopuszczalnego, a modyfikacja jego parametrów domyślnych oparta była wyłącznie na macierzy kowariancji CMA-ES.




Rysunek 9. Porównanie zbieżności wariantów BFGS w 100 wymiarach z zastosowaniem różnych metod skalowania macierzy B_0 . Losowy punkt startowy.

Rysunek 9 przedstawia krzywe zbieżności wariantów BFGS inicjowanych w losowych punktach startowych z zastosowaniem proponowanych sposobów skalowania macierzy $\mathbf{B}_0$. Górny panel wydaje się potwierdzać przypuszczenia opisane w rozdziale 3.1.3, gdzie założono, że dla $d = 100$ dopasowanie macierzy $\mathbf{C}$ do odwrotności hesjanu funkcji SDP nastąpiło około 1200. iteracji algorytmu. Inicjacja macierzą kowariancji CMA-ES uzyskaną po iteracjach ≥ 1200 skutkuje redukcją wymaganych przez BFGS ewaluacji funkcji celu rzędu ok. 35% ($\mathbf{C}_{1200}$) do ok. 85% ($\mathbf{C}_{1600}$).

Warte uwagi jest również ryzyko przedwczesnego wykorzystania informacji pochodzącej z algorytmu CMA-ES do inicjacji macierzy $\mathbf{B}_0$, co może prowadzić do spowolnienia zbieżności BFGS. W przypadku problemu stuwymiarowego dotyczy to w szczególności macierzy kowariancji uzyskanych po 600, 800 oraz 1000 iteracjach, przypadających na okres intensywnej adaptacji tej macierzy, objawiającej się spowolnieniem tempa poprawy najlepszego dotychczasowego rozwiązania w algorytmie CMA-ES (rysunek 3). Wykorzystanie macierzy z wcześniejszego etapu optymalizacji ($\mathbf{C}_{200}$ lub $\mathbf{C}_{400}$) powoduje natomiast spowolnienie zbieżności BFGS rzędu poniżej 10%.


W wysokowymiarowym przypadku najszybszą zbieżnością wykazywały się instancje BFGS z jednostkową normalizacją macierzy $\mathbf{B}_0$. W niższych wymiarowościach korzystne okazało się dodatkowe jej zmniejszenie, jednak efekt ten zanika wraz ze wzrostem wymiarowości. Wykresy obrazujące tę zależność zawiera załącznik B.

Kolejnym krokiem jest weryfikacja, czy zaobserwowana prawidłowość dotycząca wpływu metod normalizacji na zbieżność algorytmu utrzymuje się również w instancjach uruchamianych z odziedziczonym punktem startowym. Jest to kluczowa kwestia dla funkcjonowania proponowanego optymalizatora hybrydowego, w którym algorytm BFGS działa właśnie w takich warunkach.



Rysunek 10. Porównanie zbieżności algorytmu BFGS uruchamianego w średniej rozkładu populacji CMA-ES, z inicjacją opartą na macierzy jego kowariancji w zależności od sposobu normalizacji. Górny panel – 100 wymiarów, po 1200 iteracjach. Dolny panel – 20 wymiarów, po 200 iteracjach.

W kwestii normalizacji macierzy B_0 , rysunek 10 prezentujący porównanie tempa zbieżności BFGS inicjowanego macierzą C wskazuje na zachowanie zależności zauważonych w dyskusji rysunku 9 i w załączniku B. Jako że kluczowym aspektem algorytmu jest skalowalność i przyspieszenie zbieżności w wysokich wymiarowościach, w dalszej części pracy stosowana jest jednostkowa normalizacja macierzy B_0 .



Rysunek 11. Porównanie krzywych zbieżności algorytmu BFGS inicjowanego w średniej rozkładu populacji CMA-ES - 100 wymiarów, po 1200 iteracjach. Macierze B_0 podlegały normalizacji jednostkowej.

Rysunek 11 przedstawia porównanie tempa zbieżności instancji BFGS uruchamianych w punkcie m_{1200} dla $d = 100$. Na jego podstawie można stwierdzić, że wartość macierzy B_0 ma znaczący wpływ na efektywność BFGS także w przypadku rozpoczęcia działania algorytmu w punkcie położonym blisko optimum. Rozpoczynając optymalizację w punkcie osiągniętym przez CMA-ES po 1200 iteracjach, BFGS inicjowany jego macierzą kowariancji osiąga optimum ponad dwukrotnie szybciej niż wersja inicjowana macierzą jednostkową.

3.2.4 Wnioski

W tym rozdziale zweryfikowano przypuszczenia sformułowane w rozdziale 3.1.3. Potwierdzono doświadczalnie, że dla przypadku kwadratowej funkcji celu:

1. Tempo zbieżności algorytmu BFGS zależy od początkowej wartości przybliżenia odwrotności hesjanu B_0 .
2. Macierz C uzyskana przez algorytm CMA-ES po odpowiedniej liczbie iteracji stanowi wystarczająco dokładne przybliżenie odwrotności hesjanu funkcji celu do przyspieszenia zbieżności BFGS.
3. Istotnym aspektem mającym wpływ na tempo zbieżności algorytmu BFGS jest skala początkowego przybliżenia odwrotności hesjanu B_0 .
4. Inicjacja BFGS wiarygodnym przybliżeniem odwrotności hesjanu optymalizowanej funkcji ma znaczenie zarówno wtedy, gdy optymalizacja rozpoczyna się w punkcie odległym od minimum funkcji celu, jak i wówczas, gdy punkt startowy jest blisko tego minimum.

Celem dalszej części pracy jest zdefiniowanie hybrydowego algorytmu optymalizacji globalnej opartego na tych wnioskach i weryfikacja jego skuteczności w trudniejszych zadaniach optymalizacyjnych - z uwzględnieniem ograniczeń kosztowych oraz dla funkcji wielomodalnych.

3.3 Algorytm CMABFGS

3.3.1 Motywacja i zarys algorytmu

W rozdziale 3.2 empirycznie wykazano, że algorytm BFGS może wykazywać poprawę zbieżności przy inicjacji z wykorzystaniem macierzy $\mathbf{C}$ algorytmu CMA-ES. Celem dalszych badań jest weryfikacja możliwości zwiększenia efektywności CMA-ES przez hybrydyzację z tak inicjowanym BFGS. Proponowane rozwiązanie przedstawia algorytm 3.

Algorytm 3. Algorytm CMABFGS. Symbole: X_{BFGS} - zbiór rozwiązań wygenerowanych przez BFGS, n_{BFGS} - liczba ewaluacji funkcji celu wykorzystana przez BFGS. Pozostałe - por. sekcja 2.1.

```

1 Ustawienie parametrów
   | ustawienie  $\lambda, w_{i=1\dots\lambda}, c_m, c_\sigma, d_\sigma, c_c, c_1, c_\mu$ 
2 Inicjacja
   | ścieżki ewolucji:  $\mathbf{p}_\sigma = \mathbf{0}, \mathbf{p}_c = \mathbf{0}$ 
   | macierz kowariancji:  $\mathbf{C} = \mathbf{I}$ 
   | liczniki iteracji i ewaluacji funkcji celu:  $g = 0, n_{\text{eval}} = 0$ 
   | średnia rozkładu:  $\mathbf{m} \in \mathbb{R}^n$ 
   | rozmiar kroku:  $\sigma > 0$ 
   | log wygenerowanych rozwiązań:  $L = \{\}$ 
3 Dopóki nie spełniono kryterium zatrzymania:
4    $g \leftarrow g + 1$ 
5   Jeżeli  $g \% (k \cdot d) == 0$ :
6     Uruchomienie optymalizatora lokalnego
7      $X_{\text{BFGS}}, n_{\text{BFGS}} = \text{BFGS}(x_0=\mathbf{m}_g, \mathbf{B}_0=\text{normalizacja}(\mathbf{C}))$ 
8      $L \leftarrow L \cup X_{\text{BFGS}}$ 
9      $n_{\text{eval}} \leftarrow n_{\text{eval}} + n_{\text{BFGS}}$ 
10    Próbkowanie nowej populacji dla  $k = 1, \dots, \lambda$ 
11       $\mathbf{z}_k \sim N(\mathbf{0}, \mathbf{I})$ 
12       $\mathbf{y}_k = \mathbf{E}\sqrt{\Lambda}\mathbf{z}_k \sim N(\mathbf{0}, \mathbf{C})$ 
13       $\mathbf{x}_k = \mathbf{m} + \sigma\mathbf{y}_k \sim N(\mathbf{m}, \sigma^2\mathbf{C})$ 
14       $L \leftarrow L \cup \mathbf{x}_k$ 
15    Selekcja i rekombinacja
16       $\langle \mathbf{y} \rangle_w = \sum_{i=1}^\mu w_i \mathbf{y}_{i:\lambda}$ 
17      gdzie  $\sum_{i=1}^\mu w_i = 1$  i  $w_i > 0$  dla  $i = 1 \dots \mu$ 
18       $\mathbf{m} \leftarrow \mathbf{m} + c_m \sigma \langle \mathbf{y} \rangle_w$ 
19       $n_{\text{eval}} \leftarrow n_{\text{eval}} + \lambda$ 
20    Sterowanie rozmiarem kroku
21       $\mu_{\text{eff}} = \left( \sum_{i=1}^\mu w_i^2 \right)^{-1}$ 
22       $\mathbf{p}_\sigma \leftarrow (1 - c_\sigma)\mathbf{p}_\sigma + \sqrt{c_\sigma(2 - c_\sigma)\mu_{\text{eff}}} \mathbf{C}^{-\frac{1}{2}} \langle \mathbf{y} \rangle_w$ 
23       $\sigma \leftarrow \sigma \cdot \exp\left(\left(\frac{c_\sigma}{d_\sigma}\right)\left(\frac{\|\mathbf{p}_\sigma\|}{E(\|N(\mathbf{0}, \mathbf{I})\|)} - 1\right)\right)$ 
24    Adaptacja macierzy kowariancji
25       $\mathbf{p}_c \leftarrow (1 - c_c)\mathbf{p}_c + h_\sigma \sqrt{c_c(2 - c_c)\mu_{\text{eff}}} \langle \mathbf{y} \rangle_w$ 
26       $\mathbf{C} \leftarrow (1 + c_1 \delta(h_\sigma) - c_1 - c_\mu \sum w_j) \mathbf{C} + c_1 \mathbf{p}_c \mathbf{p}_c^T + c_\mu \sum_{i=1}^\lambda w_i \mathbf{y}_{i:\lambda} \mathbf{y}_{i:\lambda}^T$ 

```

Co $k \cdot d$ iteracji CMA-ES, jego punkt $\mathbf{m}$ oraz macierz $\mathbf{C}$ wykorzystane są do inicjacji instancji BFGS, skupiającej się na eksploatacji obecnego otoczenia punktu $\mathbf{m}$. Wynik zwrócony przez BFGS nie wpływa w żaden sposób na dalsze działanie CMA-ES.

3.3.2 Uwagi implementacyjne

Istnieje kilka dotyczących praktycznej implementacji algorytmu, które są warte opisanie w tym miejscu.

Ustawienia CMA-ES i BFGS opisane w sekcji 3.0.1 są stosowane także dla ich instancji działających wewnątrz CMABFGS. Budżet ewaluacji w kolejnych eksperymentach wynosi $10^4 \cdot d$ na wzór zawodów CEC [29].

Zakłada się, że wszystkie instancje CMA-ES i BFGS działające w ramach algorytmu CMABFGS posiadają wspólny budżet ewaluacji funkcji celu.

Na rzecz analizy zbieżności, algorytm traktowany jest jako jeden spójny byt - krzywe zbieżności oraz ECDF obliczane są na podstawie najlepszego dotychczasowego punktu znalezionego przez algorytm CMA-ES lub jedną z uruchomionych instancji BFGS.

3.4 Porównanie zbieżności CMA-ES, BFGS i CMABFGS z uwzględnieniem ograniczeń

3.4.1 Cel badania

Celem badania jest porównanie zbieżności algorytmu CMABFGS oraz algorytmów bazowych na dwóch funkcjach kontrolnych: analizowanej wcześniej funkcji SDP oraz funkcji Rastrigina, przedstawionej w definicji 2. W przeciwieństwie do przypadków omawianych w rozdziale 3.2, rozważane zadania uwzględniają zarówno ograniczenia kostkowe, jak i wielomodalność funkcji celu, co istotnie utrudnia proces optymalizacji.


Analiza ta stanowi krok kontrolny, pozwalający ocenić użyteczność hybrydyzacji CMA-ES i BFGS w nietrywialnych warunkach, przed weryfikacją algorytmu na wyczerpującym zestawie funkcji benchmarkowych CEC2017.

Funkcja Rastrigina

Funkcja Rastrigina określona jest wzorem

$$f(x) = 2n + \sum_{i=0}^{n-1} [x_i^2 - 2 \cos(2\pi x_i)] \quad (10)$$

Charakteryzuje ją duża liczba lokalnych minimów umieszczonych w równomiernych odstępach w liniach równoległych do osi. Duża liczba minimów lokalnych jest problematyczna dla optymalizatorów, które często nie są w stanie odnaleźć globalnego optimum funkcji umieszczonego w centrum obszaru dopuszczalnego dla $X = (0, \dots, 0)$.



Rysunek 12. Wykres konturowy funkcji Rastrigina

Definicja 2. Funkcja Rastrigina**Uwagi implementacyjne**

„Kanoniczne” ograniczenia kostkowe funkcji Rastrigina to $x \in [-5.12, 5.12]^d$. Aby ograniczenia na potrzeby badań były równe $[-100, 100]^d$ niezależnie od funkcji celu, punkty przed ewaluacją poddawane były skalowaniu $x' = \frac{5.12}{100}x = 0.0512x$. Ewaluacja na pełnym zbiorze $[-100, 100]^d$ byłaby niepożądana - skutkowałoby to zmianą liczby i gęstości rozłożenia optimów lokalnych.

3.4.2 Metodyka

Badanie zostało przeprowadzone w ten sam sposób dla wymiarowości $d \in \{10, 20, 50, 100\}$. Algorytm CMABFGS został uruchomiony 25 razy. Zbadano cztery warianty położenia ograniczeń kostkowych względem minimum globalnego - w każdym z przypadków minimum globalne leży w punkcie $x^* = (0, \dots, 0)$:

1. Optimum w środku obszaru dopuszczalnego - zbiór dopuszczalny jest kostką $[-100, 100]^d$;
2. Optimum położone w pobliżu narożnika przestrzeni dopuszczalnej, oddalone od ograniczeń o 10% szerokości obszaru dopuszczalnego - zbiór dopuszczalny jest kostką $[-180, 20]^d$;

3. Optimum położone w pobliżu narożnika przestrzeni dopuszczalnej, oddalone od ograniczeń o 0.5% szerokości obszaru dopuszczalnego - zbiór dopuszczalny jest kostką $[-199, 1]^d$;
4. Optimum położone poza narożnikiem przestrzeni dopuszczalnej, oddalone od ograniczeń o 10% szerokości obszaru dopuszczalnego - zbiór dopuszczalny jest kostką $[-220, -20]^d$;

Przypadki 1. oraz 2. nazywane będą w dalszej części rozdziału przypadkami **z zapasem względem ograniczeń**, a przypadki 3. oraz 4. przypadkami **bez zapasu względem ograniczeń**.

Zbadane warianty współczynnika k odpowiedzialnego za częstość uruchamiania algorytmu BFGS wynoszą $k \in [0.5, 1, 2, 4, 8]$. Dla $d = 10$ skutkuje to przełączaniem optymalizacji na BFGS co $[5, 10, 20, 40, 80]$ iteracji algorytmu CMA-ES.


Kryterium porównawczym algorytmów są ich krzywe zbieżności. Poza pięcioma wariantami CMABFGS, jako przypadki bazowe w punkcie startowym uruchamiane są też podstawowe wersje CMA-ES i BFGS jako warianty kontrolne.

Z racji na znaczący wpływ przypadków brzegowych na analizowane wyniki, prezentowane uśrednione krzywe zbieżności wyliczane były na podstawie 23 próbek, z wyłączeniem najniższej oraz najwyższej osiągniętej wartości funkcji celu dla każdego budżetu ewaluacji.

3.4.3 Omówienie wyników badania

Ze względu na potrzebę agregacji dużej liczby eksperymentów oraz nacisk na skalowalność rozwiązania w wyższych wymiarowościach, w tym rozdziale omawiane będą wyłącznie wyniki przypadku stuwymiarowego. Przykładowe wyniki dla mniejszych wymiarowości zawiera załącznik C.

Rysunek 13 przedstawia krzywe zbieżności dla funkcji Rastrigina dla przypadków położenia optimum globalnego z zapasem względem ograniczeń. Mimo wielomodalności optymalizowanej funkcji, warianty CMABFGS w większości przypadków cechują się szybszą zbieżnością oraz wyższą dokładnością wyznaczenia optimum niż klasyczny algorytm CMA-ES.



Rysunek 13. Krzywe zbieżności CMA-ES, CMABFGS i BFGS. Funkcja Rastrigina, 100 wymiarów, warianty ograniczeń $[-100, 100]^d$ i $[-180, 20]^d$.


W przypadku optimum położonego w centrum zbioru dopuszczalnego warta zauważenia jest znacząca poprawa rozwiązań pośrednich przez wcześniej uruchomione warianty BFGS - pomiędzy 200. a 500. iteracją. Dane dotyczące charakterystyki macierzy kowariancji nie były w tym eksperymencie analizowane, jednak tak wczesne uruchamianie BFGS w rozdziale 3.2 dla funkcji SDP bez ograniczeń kosztowych skutkowało spowolnieniem jego zbieżności. Nie jest pewne, czy doszło do znacznie szybszej adaptacji macierzy kowariancji, czy jest to przypadek zadania, gdzie mniej dokładne przybliżenie odwrotności hesjanu używanego do inicjacji BFGS jest wystarczające do poprawy wyniku. Z racji tego, że klasyczny wariant BFGS uruchamiany w początkowym punkcie startowym CMA-ES z macierzą jednostkową szybko kończy działanie (przypuszczalnie ze względu na próbę ewaluacji poza ograniczeniami), pewne jest jednak, że samo uruchomienie BFGS nie jest wystarczające do odnalezienia dobrego rozwiązania.

W przypadku optimum położonego w narożniku widoczna jest poprawa zarówno tempa odnalezienia ostatecznego rozwiązania, jak i jego jakości względem CMA-ES dla wszystkich uruchamianych wariantów CMABFGS. Warianty z $k \in \{2, 4\}$ wypadają w tym zadaniu szczególnie dobrze - poprawa tempa i jakości rozwiązania wydaje się „darmowa” - dla każdego prognozy budżetowego znajdują niegorsze rozwiązanie niż CMA-ES.

Dla $k \in \{0.5, 1\}$ można jednak zauważyć, że przedwczesne uruchamianie BFGS (przed $0.8 \cdot 10^5$ ewaluacjami funkcji celu) nie skutkuje znaczną poprawą dotychczasowego wyniku, a obciążone kosztem powodującym chwilowe spowolnienie zbieżności względem CMA-ES. Przypuszczalnie na tak wczesnym etapie optymalizacji macierz kowariancji CMA-ES jest niewystarczająco dopasowana, aby przyspieszyć działanie BFGS.

Przypadek ten pozwala sformułować kluczowy wniosek dotyczący wyboru częstości uruchamiania BFGS - istnieje potrzeba osiągnięcia kompromisu między ryzykiem, jakie podjęte jest przez częstsze jego uruchamianie oraz zyskiem w kwestii budżetu, którego można spodziewać się uruchamiając BFGS rzadziej.

Klasyczny wariant BFGS inicjowany macierzą jednostkową jest kompletnie nieskuteczny w zadaniu z ograniczeniami - zwraca rozwiązania nieznacznie lepsze od punktu startowego i wcześniej kończy działanie. Przypuszczalnie jest to spowodowane obranym sposobem uwzględniania ograniczeń kosztowych.



Rysunek 14. Krzywe zbieżności CMA-ES, CMABFGS i BFGS. Funkcja Rastrigina, 100 wymiarów, warianty ograniczeń $[-199, 1]^d$ i $[-220, -20]^d$.

Rysunek 14 przedstawia krzywe zbieżności CMA-ES oraz CMBAFGS dla przypadków położenia optimum z brakiem zapasu względem ograniczeń. Przewaga CMABFGS nad CMA-ES jest wyraźnie mniejsza ze względu na małą odległość między ograniczeniami a optimum - uruchamianie BFGS w pobliżu ograniczeń kosztowych wiąże się z ryzykiem ich naruszenia na etapie przeszukiwania kierunkowego.

Warto jednak zauważyć, że nawet w przypadku ograniczeń $[-199.0, 1.0]^d$ dla niektórych wartości k wciąż odnotowywana jest poprawa tempa znalezienia ostatecznego wyniku optymalizacji wskutek hybrydyzacji CMA-ES i BFGS. W wariancie $k = 1$ jest ona jednoznacznie obciążona spowolnieniem zbieżności CMABFGS względem CMA-ES na wcześniejszych etapach działania, jednak wariant $k = 2$ przyspiesza zbieżność bez widocznego kosztu, podobnie do przypadku z ograniczeniami $[-180, 20]^d$. Wariant z $k = 0.5$ zużywa natomiast zbyt dużą

część budżetu na częste uruchomienia BFGS i osiąga jednoznacznie gorsze wyniki pośrednie od klasycznego CMA-ES.

Pogorszenie efektywności spowodowane uruchamianiem BFGS szczególnie widoczne jest w przypadku, w którym optimum jest położone poza zbiorem dopuszczalnym. Wykorzystywany wariant BFGS nie umożliwia wystarczająco granularnej zmiany parametrów przeszukiwania liniowego, aby efektywnie temu przeciwdziałać. Wariant $k = 2$ wydaje się marginalnie poprawiać jakość najlepszego dotychczasowego punktu około $0.8 \cdot 10^5$ ewaluacji funkcji celu, jest to jednak pomijalne. Warianty $k \in \{4, 8\}$ uruchamiane były w tym przypadku po osiągnięciu końcowego rozwiązania i nie wykazały różnic względem klasycznego CMA-ES.

Komentarz dotyczący wyników dla funkcji SDP

Przypadek funkcji SDP jest idealnie dopasowany do algorytmu BFGS, w związku z czym we wszystkich badanych wymiarowościach zaobserwowano szybkie wyznaczenie optimum globalnego, gdy było ono położone w środku obszaru dopuszczalnego. W przypadku ograniczeń $[-180, 20]^d$ początkowe uruchomienia BFGS nie skutkowały znaczącą poprawą wyniku optymalizacji, jednak po odpowiednim przybliżeniu odwrotności hesjanu macierzą $\mathbf{C}$ następowało dokładne wyznaczenie optimum globalnego po wykorzystaniu mniejszej liczby ewaluacji, niż w w przypadku klasycznego algorytmu CMA-ES.

W przypadkach bez zapasu względem ograniczeń, tempo zbieżności CMA-ES było tak szybkie, że hybrydyzacja miała nikły wpływ na wynik optymalizacji. Przykładowe rysunki zawiera załącznik C.

3.4.4 Wnioski

W rozdziale zweryfikowano proponowany optymalizator CMABFGS w rozwiązywaniu przykładowych zadań optymalizacji z ograniczeniami kosztowymi.

Wykazano empirycznie, że CMABFGS, uruchamiający BFGS odpowiednio często, przewyższa efektywnością klasyczny algorytm CMA-ES, *także w zadaniu optymalizacji funkcji wielomodalnych.*

Algorytm CMABFGS wydaje się być szczególnie obiecującym rozwiązaniem w przypadkach, w których poszukiwane optimum globalne funkcji celu jest położone wewnątrz zbioru dopuszczalnego. W tych warunkach zauważono największe przyspieszenie końcowej zbieżności CMABFGS względem CMA-ES nieobarczone jej spowolnieniem we wcześniejszych etapach działania. W analizowanych przypadkach wraz ze zbliżaniem się optimum globalnego do granicy zbioru dopuszczalnego, przewaga algorytmu CMABFGS malała. W przypadku położenia optimum globalnego poza zbiorem dopuszczalnym, użycie BFGS wydaje się zbędną modyfikacją CMA-ES. Jako że BFGS nie jest algorytmem zaprojektowanym z myślą o optymalizacji z uwzględnieniem ograniczeń, stanowi to dość łatwy do wyprowadzenia wniosek.

Zauważono także potrzebę osiągnięcia kompromisu między częstością uruchamiania BFGS a jego wpływem na wyczerpanie budżetu ewaluacji funkcji celu. Wzmoczona częstość uruchamiania BFGS wydaje się być obciążona większym ryzykiem - jeżeli w pewnym momencie optymalizacji pojawią się korzystne dla BFGS warunki, zostaną one prędzej wykorzystane, co skutkuje oszczędzeniem większej części budżetu ewaluacji. Jednak przypadku zadania

niekorzystnego dla BFGS, jego nadmierne uruchamianie skutkuje utratą znaczącej części budżetu, w zamian za nikłe korzyści wynikające z tych uruchomień. Mniejsza częstość uruchamiania BFGS jest wyborem bezpieczniejszym - przeznaczają się na niego mniejszą część budżetu. W zadaniach niekorzystnych dla BFGS jest to pożądane, gdyż uruchomienia te nie niosą korzyści, jednak w innych przypadkach prowadzi to do niewykorzystania potencjalnie dobrego momentu na przyspieszenie optymalizacji lokalnej.

W celu weryfikacji zaproponowanego algorytmu w szerokiej gamie zadań o różnych charakterystykach, w kolejnym rozdziale zostanie przedstawiona analiza porównawcza CMA-ES oraz CMABFGS na funkcjach z zestawu benchmarkowego CEC2017. Pozwoli ona na bardziej wszechstronne zbadanie właściwości CMABFGS.

3.5 Porównanie zbieżności algorytmów CMA-ES, BFGS oraz CMABFGS na zbiorze funkcji CEC2017

3.5.1 Cel badania

Celem badania jest porównanie tempa zbieżności algorytmu CMABFGS ze stosowanymi oddzielnie CMA-ES oraz BFGS w warunkach benchmarkowych dla zestawu funkcji CEC2017. Porównanie na standardowym zestawie benchmarkowym pozwoli sformułować ilościowe wnioski dotyczące potencjalnych korzyści z zastosowania proponowanej metody hybrydyzacji.

Zestaw CEC2017 składa się z 30 funkcji, zarówno uni-, jak i multimodalnych, o różnych stopniach trudności i właściwościach. Funkcje są podzielone na cztery kategorie:

1. Funkcje 1-3 - funkcje unimodalne;
2. Funkcje 4-10 - proste funkcje multimodalne;
3. Funkcje 11-20 - funkcje hybrydowe - punkty poddawane ewaluacji dzielone są na N podwektorów, z których każdy ewaluowany jest przez inną funkcję ($N \in \{3, 4, 5, 6\}$);
4. Funkcje 21-30 - funkcje złożone - składają się z N indywidualnych funkcji, których wartości sumowane są na podstawie ich wag ($N \in \{3, 4, 5, 6\}$);

Zgodnie z regulacjami wprowadzonymi na potrzeby CEC, optima globalne funkcji muszą znaleźć się w zakresie $[-80, 80]^d$ [29]. Zbiór dopuszczalny zdefiniowany jest jako $[-100, 100]^d$, w związku z czym sposób uwzględniania ograniczeń kostkowych nie powinien w tym przypadku istotnie wpływać na działanie BFGS.

3.5.2 Metodyka

Badanie zostało przeprowadzone dla wymiarowości $d \in \{10, 30, 50, 100\}$.

Otrzymane krzywe zbieżności oraz ECDF podlegały uśrednieniu na podstawie 25 niezależnych uruchomień z różnych punktów startowych. Kryterium użytym do zbudowania ostatecznego rankingu optymalizatorów jest miara pola pod powierzchnią uśrednionych ze wszystkich 30 funkcji krzywych ECDF, używana przykładowo w [13].

Pole pod krzywą ECDF obliczane jest przez całkowanie numeryczne przy użyciu metody trapezów.

Zbiór wartości progów budżetowych stanowiących oś X krzywych wyznaczono jako 50 punktów równomiernie rozmieszczonych w skali logarytmicznej między 0 a $10^4 \cdot d$ (maksymalny budżet ewaluacji).

Poziomy satysfakcji stosowane dla każdej z funkcji były wspólne dla wszystkich algorytmów, zostały wyznaczone zgodnie z opisem przedstawionym w rozdziale 2.3.2.

3.5.3 Omówienie wyników badania

Analogicznie do rozdziału 3.4, w tym rozdziale zostanie zawarte porównanie wyników przypadku stuwymiarowego, z wyjątkiem zagregowanej miary pól pod ECDF. Omówione zostaną trendy zaobserwowane wśród wyników na podstawie krzywych zbieżności pojedynczych funkcji oraz zagregowane krzywe ECDF.


Analiza krzywych zbieżności

Analiza krzywych zbieżności dla funkcji z zestawu CEC2017 pozwala wyznaczyć kilka powtarzalnych wzorców zachowania algorytmów. Każda z grup zostanie omówiona wraz z reprezentatywnym jej przykładem. Istotne jest zaznaczenie, że analiza ta jest wizualna i pełni rolę pomocniczą przed przeprowadzeniem zagregowanej analizy. Heurystyczny przydział do poszczególnych grup przedstawiono w tabeli 4.

Tabela 4. Podział wyników benchmarku CEC2017 dla $d = 100$ na grupy - wizualna interpretacja uśrednionych krzywych zbieżności


Opis grupy funkcji	Przynależące funkcje
Wyraźne przyspieszenie wyznaczenia lub poprawa końcowego wyniku przez BFGS	3, 5, 7, 8, 11, 12, 13, 14, 15, 18, 21, 23, 24, 30
Przyspieszenie osiągnięcia dobrych pośrednich wyników pomijalnie niskim kosztem ⁹ , najlepszy wynik końcowy nieosiągnięty przez BFGS dla wszystkich wartości k	4, 16, 17, 26
Wyraźne spowolnienie spowodowane hybrydyzacją niezależnie od wartości k	2, 6
Wpływ hybrydyzacji niejednoznaczny (por. rozdział 2.3.1)	1, 9, 10, 19, 20, 22, 25, 27, 28, 29

⁹Pomijalny koszt oznacza, że niemożliwe jest przez analizę wizualną wyznaczenie punktu, dla którego $f_{\text{CMA-ES}} < f_{\text{CMABFGS}}$



Rysunek 15. Krzywe zbieżności CMA-ES oraz CMABFGS dla funkcji 5 z zestawu CEC2017


Na rysunku 15 przedstawione są przykładowe krzywe zbieżności badanych algorytmów dla najliczniejszej grupy zadań. Dla zadań z tej grupy hybrydyzacja skutkowała jednoznaczną oszczędnością liczby ewaluacji oraz przyspieszeniem zbieżności niezależnie od wartości k , nie powodując zauważalnego spowolnienia zbieżności względem klasycznego algorytmu CMA-ES na żadnym etapie optymalizacji.



Rysunek 16. Krzywe zbieżności CMA-ES oraz CMABFGS dla funkcji 16 z zestawu CEC2017


Rysunek 16 przedstawia krzywe zbieżności badanych algorytmów dla funkcji 16 z zestawu CEC. Jest to przykładowe zadanie z grupy, dla której, mimo braku poprawy jakości rozwiązania końcowego, hybrydyzacja prowadzi do szybszego uzyskiwania lepszych rozwiązań pośrednich, nie pogarszając jednocześnie tempa uzyskania wyniku końcowego względem

CMA-ES. Jest to istotny przypadek z punktu widzenia optymalizacji z ograniczonym budżetem ewaluacji.




Rysunek 17. Krzywe zbieżności CMA-ES oraz CMABFGS dla f. 19 z zestawu CEC2017

Trzecią wyodrębnioną kategorią są funkcje, dla których uruchomienia BFGS skutkują osiągnięciem niższych wartości pośrednich w trakcie optymalizacji, okupione są jednak gorszym końcowym wynikiem lub opóźnieniem w jego uzyskaniu. Koszt działania BFGS względem ewaluacji, które mogłyby zostać w przeciwnym wypadku wykorzystane przez CMA-ES jest zbyt wysoki, aby jednoznacznie stwierdzić, który z algorytmów jest efektywniejszy. Jest to druga najliczniejsza kategoria spośród omawianych.



Rysunek 18. Krzywe zbieżności CMA-ES oraz CMABFGS dla f. 6 z zestawu CEC2017

Niektóre funkcje z zestawu okazywały się wyraźnie niekorzystnym środowiskiem do uruchamiania BFGS. W ich przypadku hybrydyzacja była równoznaczna z marnowaniem budżetu, a wraz ze wzrostem częstości przeszukiwania lokalnego widoczne było coraz większe opóźnienie wyznaczenia ostatecznego wyniku optymalizacji. Za przykład służy funkcja 6 ukazana na rysunku 18.



Rysunek 19. Krzywe zbliżności CMA-ES oraz CMABFGS dla f. 3 z zestawu CEC2017


Wartymi wspomnienia są także pojedyncze przypadki, w których uruchomienie BFGS skutkowało dokładniejszym wyznaczeniem optimum globalnego lub wyznaczeniem go wtedy, gdy nie udało się to algorytmowi CMA-ES, przykładowo funkcja 3 ukazana na rysunku 19. Są to jednak pojedyncze przypadki.

Bazowy wariant BFGS inicjowany macierzą jednostkową nie osiągnął znaczącej poprawy wyniku względem punktu startowego dla żadnej z analizowanych funkcji.

Zagregowana analiza wyników przy pomocy krzywych ECDF

Powyższa analiza jakościowa pokazuje, że wpływ hybrydyzacji w zbiorze CEC2017 nie jest jednoznaczny - zaobserwowano pełne spektrum wpływu włączenia BFGS w proces optymalizacji, od kilkukrotnego przyspieszenia zbieżności do kilkukrotnego jej spowolnienia. W celu uogólnienia obserwowanych tendencji i uniknięcia nadinterpretacji przypadków szczególnych, w dalszej części rozdziału przeprowadzono analizę zagregowaną na podstawie krzywych ECDF.

Rysunek 20 ukazuje zagregowane krzywe ECDF na zestawie funkcji benchmarkowych CEC2017 dla $d \in \{50, 100\}$. Bazowy wariant BFGS został wyłączony z analizy na podstawie ECDF ze względu na zauważalnie niższą efektywność na zbiorze CEC niż CMA-ES oraz CMABFGS.



Rysunek 20. Zagregowane krzywe ECDF dla całego zestawu funkcji CEC. 100 oraz 50 wymiarów.

Z wizualnej analizy uśrednionych krzywych ECDF uzyskanych w wyższych wymiarowościach wynika, iż dla wariantów o $k \in \{2, 4, 8\}$ nie występuje punkt, w którym $\text{ECDF}_{\text{CMABFGS}} < \text{ECDF}_{\text{CMA-ES}}$. Na tej podstawie, przyjmując *wizualną* analizę zagregowanych krzywych ECDF jako kryterium porównawcze, algorytm CMABFGS można uznać za skuteczniejszy od CMA-ES dla zestawu funkcji CEC2017 w tych wymiarowościach. Warianty $k \in \{0.5, 1\}$ nie wykazują tej zależności - w późniejszym etapie optymalizacji następuje punkt przecięcia ich krzywych z CMA-ES, co jest skutkiem zużycia znaczącej części budżetu na uruchomienia BFGS. Należy zaznaczyć, że porównanie to ma charakter wizualny i odnosi się do przyjętej skali osi, w szczególności skali logarytmicznej budżetu oraz sposobu wyznaczenia równo oddzielonych na skali logarytmicznej progów budżetowych.

Analiza porównawcza na podstawie miary pól pod zagregowanymi krzywymi ECDF

Kolejną proponowaną metryką porównawczą jest znormalizowane pole pod krzywą ECDF wyznaczoną na podstawie wszystkich uruchomień optymalizatora. Miarę tę można interpretować jako uśrednioną skuteczność algorytmu w całym przebiegu optymalizacji, uwzględniającą zarówno tempo poprawy rozwiązania, jak i jego jakość końcową. Porównanie wyników algorytmów z wykorzystaniem tej metryki pozwala na kwantyzację korzyści wynikających z

wcześniejszego uzyskiwania przez CMABFGS lepszych rozwiązań pośrednich kosztem części dostępnego budżetu ewaluacji w porównaniu do CMA-ES. Tabela 5 przedstawia znormalizowane wobec najlepszego wyniku stosunki pól pod krzywymi w każdym z badanych wymiarów.

Tabela 5. Zestawienie znormalizowanych wartości pól pod ECDF we wszystkich badanych wymiarowościach

Optymalizator	d=10	d=30	d=50	d=100
CMA-ES	<u>0.982</u>	<u>0.946</u>	<u>0.941</u>	<u>0.936</u>
CMABFGS-0.5	0.999	0.988	0.988	0.983
CMABFGS-1.0	1	1	1	1
CMABFGS-2.0	0.999	0.998	1	0.999
CMABFGS-4.0	0.994	0.994	0.995	0.986
CMABFGS-8.0	0.99	0.988	0.98	0.969
Maksymalna różnica	1.8%	5.4%	5.9%	6.4%

Żaden z badanych wariantów algorytmu CMABFGS nie osiągnął mniejszej miary pola pod zagregowaną krzywą niż odpowiadający mu klasyczny algorytm CMA-ES. Wobec tego, przyjmując miarę tę jako wyznacznik jakości przeciętnego rozwiązania algorytmu na dowolnym etapie optymalizacji, można uznać algorytm CMABFGS za niegorszy od CMA-ES według przyjętej miary zagregowanej w zadaniach z zestawu CEC2017.

W każdej z badanych wymiarowości najwyższą miarę pola osiągnęły warianty CMABFGS, gdzie $k \in \{1, 2\}$.

Tendencja wzrostowa różnicy pól pod ECDF między klasycznym CMA-ES a CMABFGS wraz ze wzrostem wymiarowości wydaje się wskazywać na szczególną użyteczność CMABFGS w wysokowymiarowych problemach. Wzrastająca wraz z wymiarowością korzyść z hybrydyzacji jest przypuszczalnie związana z wybraną w rozdziale 3.2 metodą normalizacji macierzy, niebędącą najefektywniejszym dla niskich wymiarowości wariantem w przeprowadzonych eksperymentach.

Różnica pól pod krzywymi ECDF uzyskana poprzez hybrydyzację z użyciem BFGS wskazuje na potencjalną korzyść płynącą z jej wykorzystania w praktycznych przypadkach rozwiązywania skomplikowanych wysokowymiarowych problemów optymalizacyjnych.

3.5.4 Wniosek

Na podstawie dwóch obranych metryk najskuteczniejszymi wariantami algorytmu CMABFGS okazały się instancje, gdzie $k \in \{1, 2\}$. Według przeprowadzonych porównań zagregowanych wyników na zestawie funkcji CEC2017, można uznać je za korzystną modyfikację algorytmu CMA-ES. Należy jednak podkreślić, że uzyskane wnioski zależą od przyjętych metryk porównawczych oraz charakteru analizowanego zbioru funkcji benchmarkowych.

4 Podsumowanie

4.1 Podsumowanie badań

W rozdziale 3.1 zweryfikowano obecne w literaturze spostrzeżenia wskazujące na zjawisko zbieżności macierzy kowariancji algorytmu CMA-ES do odwrotności hesjanu kwadratowej funkcji celu podczas optymalizacji. Przedstawiono także korelację między stanem macierzy kowariancji a tempem zbieżności algorytmu.

W rozdziale 3.2 potwierdzono na przykładzie BFGS, że istnieje możliwość zwiększenia efektywności algorytmów zmiennej metryki z wykorzystaniem przybliżenia odwrotności hesjanu pozyskanego na podstawie macierzy kowariancji CMA-ES. Pokazano także, że pozytywny wpływ na zbieżność BFGS zachodzi dopiero po pewnym czasie działania CMA-ES, gdy jego macierz kowariancji stanowi wystarczająco dokładne przybliżenie odwrotności hesjanu funkcji celu.

Badania przeprowadzone w rozdziałach 3.4 oraz 3.5 weryfikowały wpływ hybrydyzacji z przyspieszoną wersją BFGS na efektywność algorytmu CMA-ES. W 3.4 pokazano, że hybrydyzacja z optymalizatorem lokalnym może skutkować przyspieszeniem zbieżności algorytmu, także dla zadań wielomodalnych uwzględniających ograniczenia kostkowe. Zauważono wpływ położenia globalnego optimum funkcji celu względem ograniczeń kostkowych na efektywność hybrydyzacji - w wymagających przypadkach, gdy optimum położone było bardzo blisko ograniczeń lub poza obszarem dopuszczalnym, korzyść ze stosowania BFGS zanikała.

W zakresie dwóch obranych metryk, proponowany hybrydowy optymalizator osiągnął lepsze uśrednione wyniki na zestawie CEC2017 od klasycznego CMA-ES dla każdej z badanych wymiarowości. Uśredniona poprawa efektywności na przekrojowym zestawie trzydziestu funkcji o różnej charakterystyce jest zjawiskiem wskazującym na korzyść płynącą ze sprzężenia algorytmów.

Warto jednak zaznaczyć, że zagregowane wyniki nie świadczą o jednoznacznej poprawie efektywności płynącej z hybrydyzacji niezależnie od rozważanego zadania. Dla części funkcji z zestawu CEC2017 zaobserwowano wyraźne spowolnienie zbieżności CMABFGS w porównaniu do CMA-ES. Zgodnie z twierdzeniem *No Free Lunch*, poprawa efektywności zaobserwowana na danym zestawie zadań może być obciążona jej pogorszeniem dla innej klasy problemów [25]. Ograniczenie negatywnych efektów proponowanej hybrydyzacji w tych zadaniach wymaga dalszych badań.

4.2 Rekomendacje do przyszłych badań

Przedstawione w pracy wyniki pokazują zarówno potencjał proponowanego podejścia, jak i jego ograniczenia, stanowiące obiecujący kierunek dalszych badań.

Przyspieszenie BFGS przy pomocy macierzy kowariancji CMA-ES okazało się korzystne, skutkując znaczącym przyspieszeniem działania algorytmu w odpowiednich warunkach. Potencjalnie istotnym kierunkiem badań jest podjęcie analogicznej próby dla innych metod zmiennej metryki, w szczególności L-BFGS-B, stanowiącej oszczędniejszą alternatywę BFGS uwzględniającą ograniczenia kostkowe. Istotną uwagą jest tu fakt, że większość implementacji

L-BFGS-B nie umożliwia inicjacji algorytmu z inną wartością przybliżenia hesjanu funkcji celu niż domyślna.

Uruchamianie BFGS co $k \cdot d$ iteracji proponowane w pracy okazało się techniką skuteczną, jednak zdefiniowaną heurystycznie. Bardziej szczegółowe zbadanie zmian metryk macierzy kowariancji w celu wykrycia momentu, w którym uruchomienie optymalizatora lokalnego może być korzystne i zdefiniowanie kryteriów przełączania między algorytmami na tej podstawie stanowi istotny kierunek dalszych badań wykazujący potencjał obniżenia kosztu zbędnych uruchomień optymalizatora lokalnego.

W zakresie pracy zbadano wyłącznie jeden sposób uwzględniania ograniczeń kosztowych w przypadku BFGS, polegający na przerywaniu działania algorytmu przy pierwszej próbie ewaluacji funkcji celu poza obszarem dopuszczalnym. Motywacją tego wyboru było odwzorowanie środowiska, w którym funkcja celu pozostaje niezdefiniowana poza tym obszarem ze względu na domenowe ograniczenia dopuszczalności rozwiązań (ang. *feasibility constraints*). Potencjalnym kierunkiem dalszych badań jest uwzględnienie ograniczeń kosztowych poprzez zastosowanie zastępczej funkcji kary, co mogłoby przeciwdziałać przedwczesnemu kończeniu działania BFGS na etapie przeszukiwania liniowego.

Na potrzeby badań wyznaczono empirycznie skalę normalizacji macierzy B_0 jako jednostkową, ze względu na zadowalające wyniki działania algorytmu w wysokich wymiarowościach, poświęcając w pewnym sensie potencjalne zwiększenie efektywności w przypadkach $d < 50$. Szczegółową dyskusję tej decyzji i jej implikacji w innych zadaniach optymalizacji zawiera załącznik B.

4.3 Ograniczenia badań

Analiza porównawcza algorytmów CMA-ES i CMABFGS przeprowadzona została na podstawie relatywnie wąskiego zbioru kryteriów porównawczych. Istotne jest potwierdzenie otrzymanych wyników dla szerszego zakresu zestawów benchmarkowych z wykorzystaniem większej ilości metryk, np. badanie krzywych ECDF w stylu COCO (*runtime ECDF*) lub testów statystycznych.

Zaobserwowana poprawa wydajności CMA-ES zdaje się rosnać wraz ze wzrostem wymiarowości, są to jednak jedynie przypuszczenia, które należałoby zweryfikować w dalszych badaniach.

4.4 Ostateczne wnioski

Proponowany sposób modyfikacji algorytmu CMA-ES przez hybrydyzację z BFGS inicjowanym za pomocą macierzy kowariancji CMA-ES wydaje się korzystną modyfikacją algorytmu w kontekście zwiększenia jego efektywności w analizowanych zadaniach. Wykorzystanie macierzy kowariancji CMA-ES do przyspieszenia działania metod zmiennej metryki stanowi potencjalny kierunek dalszych badań w dziedzinie optymalizacji globalnej w przestrzeni ciągłej.

Podziękowania

Praca powstała z wykorzystaniem polskiej infrastruktury obliczeniowej PLGrid (Centrum HPC: CI TASK). Wyrażam wdzięczność za udostępnienie sprzętu komputerowego i wsparcie w ramach grantu obliczeniowego nr PLG/2025/018266.

Bibliografia

- [1] J. Nocedal i S. J. Wright, *Numerical Optimization*, 2. wyd. w Springer Series in Operations Research and Financial Engineering. Springer, 2006. doi: 10.1007/978-0-387-40065-5.
- [2] S. M. Almufti, „Historical survey on metaheuristics algorithms”, *International Journal of Scientific World*, t. 7, nr 1, s. 1, 2019.
- [3] B. F. Azevedo, A. M. A. Rocha, i A. I. Pereira, „Hybrid approaches to optimization and machine learning methods: a systematic literature review”, *Machine Learning*, t. 113, nr 7, s. 4055–4097, 2024.
- [4] D. Molina, F. Moreno-García, i F. Herrera, „Analysis among winners of different IEEE CEC competitions on real-parameters optimization: Is there always improvement?”, w *2017 IEEE congress on evolutionary computation (CEC)*, 2017, s. 805–812.
- [5] A. Auger i N. Hansen, „A restart CMA evolution strategy with increasing population size”, w *2005 IEEE congress on evolutionary computation*, 2005, s. 1769–1776.
- [6] T. Liao i T. Stützle, „Benchmark results for a simple hybrid algorithm on the CEC 2013 benchmark set for real-parameter optimization”, w *2013 IEEE Congress on Evolutionary Computation*, 2013, s. 1938–1944. doi: 10.1109/CEC.2013.6557796.
- [7] J. Arabas i D. Jagodziński, „Toward a matrix-free covariance matrix adaptation evolution strategy”, *IEEE Transactions on Evolutionary Computation*, t. 24, nr 1, s. 84–98, 2019.
- [8] N. Hansen, S. Muller, i P. Koumoutsakos, „Reducing the time complexity of the derandomized evolution strategy with covariance matrix adaptation (CMA-ES).”, *Evolutionary Computation*, t. 11, nr 1, s. 1–18, 2003.
- [9] T. Bäck i H.-P. Schwefel, „An overview of evolutionary algorithms for parameter optimization”, *Evolutionary computation*, t. 1, nr 1, s. 1–23, 1993.
- [10] N. Hansen, „The CMA Evolution Strategy: A Tutorial”. [Online]. Dostępne na: <https://arxiv.org/abs/1604.00772>
- [11] N. Hansen, „Covariance Matrix Adaptation Evolution Strategy (CMA-ES) - slajdy”. Dostęp: 9 stycznia 2026. [Online]. Dostępne na: <http://www.cmap.polytechnique.fr/~nikolaus.hansen/copenhagen-cma-es.pdf>
- [12] Y. Akimoto, „Analysis of a Natural Gradient Algorithm on Monotonic Convex-Quadratic-Composite Functions”. [Online]. Dostępne na: <https://arxiv.org/abs/1204.4141>
- [13] R. Biedrzycki, „Handling bound constraints in CMA-ES: An experimental study”, *Swarm and Evolutionary Computation*, t. 52, s. 100627, 2020.
- [14] A. W. Mohamed, A. A. Hadi, A. M. Fattouh, i K. M. Jambi, „LSHADE with semi-parameter adaptation hybrid with CMA-ES for solving CEC 2017 benchmark problems”, w *2017 IEEE Congress on evolutionary computation (CEC)*, 2017, s. 145–152.

- [15] F. Zhao, H. Bao, L. Wang, X. He, i Jonrinaldi, „A hybrid cooperative differential evolution assisted by CMA-ES with local search mechanism”, *Neural Computing and Applications*, t. 34, nr 9, s. 7173–7197, 2022.
- [16] C. G. Broyden, „The convergence of a class of double-rank minimization algorithms”, *IMA Journal of Applied Mathematics*, t. 6, nr 1, s. 76–90, 1970, doi: 10.1093/imamat/6.1.76.
- [17] R. Fletcher, „A new approach to variable metric algorithms”, *The Computer Journal*, t. 13, nr 3, s. 317–322, 1970, doi: 10.1093/comjnl/13.3.317.
- [18] D. Goldfarb, „A family of variable-metric methods derived by variational means”, *Mathematics of Computation*, t. 24, nr 109, s. 23–26, 1970, doi: 10.1090/S0025-5718-1970-0258249-6.
- [19] D. F. Shanno, „Conditioning of quasi-Newton methods for function minimization”, *Mathematics of Computation*, t. 24, nr 111, s. 647–656, 1970, doi: 10.1090/S0025-5718-1970-0274029-X.
- [20] R. H. Byrd, P. Lu, J. Nocedal, i C. Zhu, „A limited memory algorithm for bound constrained optimization”, *SIAM Journal on Scientific Computing*, t. 16, nr 5, s. 1190–1208, 1995, doi: 10.1137/0916069.
- [21] S.-Z. Zhao, J. J. Liang, P. N. Suganthan, i M. F. Tasgetiren, „Dynamic multi-swarm particle swarm optimizer with local search for large scale global optimization”, w *2008 IEEE congress on evolutionary computation (IEEE world congress on computational intelligence)*, 2008, s. 3845–3852.
- [22] A. Zamuda, J. Brest, B. Boskovic, i V. Zumer, „Differential evolution with self-adaptation and local search for constrained multiobjective optimization”, w *2009 IEEE congress on evolutionary computation*, 2009, s. 195–202.
- [23] N. Hansen, S. Finck, R. Ros, i A. Auger, „Real-Parameter Black-Box Optimization Benchmarking 2009: Noiseless Functions Definitions”, Research Report RR-6829, 2009. [Online]. Dostępne na: <https://inria.hal.science/inria-00362633>
- [24] N. Hansen, A. Auger, R. Ros, O. Mersmann, T. Tušar, i D. Brockhoff, „COCO: a platform for comparing continuous optimizers in a black-box setting”, *Optimization Methods and Software*, t. 36, nr 1, s. 114–144, sie. 2020, doi: 10.1080/10556788.2020.1808977.
- [25] D. H. Wolpert i W. G. Macready, „No free lunch theorems for optimization”, *IEEE transactions on evolutionary computation*, t. 1, nr 1, s. 67–82, 2002.
- [26] A. P. Piotrowski, J. J. Napiorkowski, i A. E. Piotrowska, „Choice of benchmark optimization problems does matter”, *Swarm and Evolutionary Computation*, t. 83, s. 101378, 2023, doi: <https://doi.org/10.1016/j.swevo.2023.101378>.
- [27] R. Biedrzycki, „Comparison with state-of-the-art: Traps and pitfalls”, w *2021 IEEE Congress on Evolutionary Computation (CEC)*, 2021, s. 863–870.
- [28] M. Nomura i M. Shibata, „cmaes : A Simple yet Practical Python Library for CMA-ES”, *arXiv preprint arXiv:2402.01373*, 2024.

- [29] N. H. Awad, M. Z. Ali, P. N. Suganthan, J. J. Liang, i B. Y. Qu, „ Problem Definitions and Evaluation Criteria for the CEC 2017 Special Session and Competition on Single Objective Real-Parameter Numerical Optimization ”. Dostęp: 11 stycznia 2026. [Online]. Dostępne na: <https://github.com/P-N-Suganthan/CEC2017-BoundConstrained/blob/master/Definitions%20of%20%20CEC2017%20benchmark%20suite%20final%20version%20updated.pdf>
- [30] D. F. Shanno i K. H. Phua, „Matrix Conditioning and Nonlinear Optimization”, *Mathematical Programming*, t. 14, nr 1, s. 149–160, 1978, doi: 10.1007/BF01588962.


Spis załączników

A	Kod źródłowy eksperymentów	44
B	Porównanie metod skalowania macierzy B_0 BFGS	45
C	Wyniki eksperymentu CMABFGS z uwzględnieniem ograniczeń dla funkcji SDP oraz Rastrigina dla $d < 100$	50


A Kod źródłowy eksperymentów

Kod źródłowy wszystkich eksperymentów opisywanych w pracy dostępny jest pod adresem <https://github.com/mbienkowsk/cmabfgs-research/>.


B Porównanie metod skalowania macierzy B_0 BFGS




Rysunek A.1. Porównanie zbieżności wariantów BFGS w 10 wymiarach z zastosowaniem różnych metod normalizacji wejściowej odwrotności hesjanu. Losowy punkt startowy.



Rysunek A.2. Porównanie zbieżności wariantów BFGS w 20 wymiarach z zastosowaniem różnych metod normalizacji wejściowej odwrotności hesjanu. Losowy punkt startowy.



Rysunek A.3. Porównanie zbieżności wariantów BFGS w 50 wymiarach z zastosowaniem różnych metod normalizacji wejściowej odwrotności hesjanu. Losowy punkt startowy.




Rysunek A.4. Porównanie zbieżności BFGS inicjowanego odwrotnością hesjanu funkcji celu w zależności od zastosowanej metody normalizacji

Z wyników dla wymiarowości $d < 50$ wynika wyższość normalizacji macierzy B_0 z dodatkowym czynnikiem zmniejszającym rzędu $d^{-\frac{1}{2}}$. Widoczne jest, że prawidłowość ta zanika wraz ze wzrostem wymiarowości problemu - dla $d = 50$ rozwiązaniem lepszym wydaje się skalowanie jednostkowe, różnica w tempie zbieżności BFGS nie jest jednak tak znacząca, jak


w przypadku $d = 100$ (rysunek 9). Na dalsze potrzeby pracy zdecydowano się na stosowanie skalowania jednostkowego ze względu na wagę przykładaną stosowaniu zadania w wysokowymiarowych problemach.

Ważne jest jednak, aby zauważyć, że zaproponowana skala została wyznaczona w sposób empiryczny i zależy także od ograniczeń kostkowych problemu - krok wykonywany przez BFGS inicjowany macierzą o jednostkowej normie jest względnie znacznie krótszy przy ograniczeniach $[-100, 100]^d$ niż $[-1, 1]^d$. Jednym z proponowanych kierunków przyszłych badań jest znalezienie solidniejszej metody normalizacji, biorącej pod uwagę m.in. wymiarowość problemu i rozmiar obszaru dopuszczalnego lub zastosowanie jednego ze sposobów skalowania opisanych w [30].

C Wyniki eksperymentu CMABFGS z uwzględnieniem ograniczeń dla funkcji SDP oraz Rastrigina dla $d < 100$




Rysunek A.5. Krzywe zbieżności CMA-ES, CMABFGS i BFGS. Funkcja Rastrigina, 50 wymiarów, warianty ograniczeń $(-100, 100)$ i $(-180, 20)$.




Rysunek A.6. Krzywe zbieżności CMA-ES, CMABFGS i BFGS. Funkcja Rastrigina, 50 wymiarów, warianty ograniczeń $(-199, 1)$ i $(-220, -20)$.

W przypadku $d = 50$ korzyść płynąca z hybrydyzacji z BFGS wydaje się zanikać szybciej, niż dla $d = 100$. Przypuszczalnie jest to związane z obranym sposobem skalowania macierzy B_0 . Tendencja do zmniejszenia korzyści z hybrydyzacji wraz z przesuwaniem optimum w stronę ograniczeń przestrzeni przeszukiwań zauważona w rozdziale 3.4 utrzymuje się w niższych wymiarowościach.



Rysunek A.7. Krzywe zbieżności CMA-ES, CMABFGS i BFGS. Funkcja SDP, 100 wymiarów, warianty ograniczeń $(-100, 100)$ i $(-180, 20)$.



Rysunek A.8. Krzywe zbieżności CMA-ES, CMABFGS i BFGS. Funkcja SDP, 100 wymiarów, wariant ograniczeń $(-199, 1)$